

เอกสารโครงงานฉบับความก้าวหน้า ครั้งที่ 2

ระบบแนะนำสินค้าเชิงสนทนาด้วยปัญญาประดิษฐ์

AI-Based Conversational Product Recommendation System

โดย
663380236-4 นายศจิษฐา ศีลธรรมดี
663380215-2 นายนิติธร คชรัตน์

อาจารย์ที่ปรึกษา
อ.ดร.พงษ์ศธร จันทร์ยอย

รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษา
วิชา CP354 771 โครงงานคอมพิวเตอร์ 1
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
วิทยาลัยการคอมพิวเตอร์
มหาวิทยาลัยขอนแก่น
ปีการศึกษา 2569

ศจิษฐา ศีลธรรมดี และ นิติธร คชรัตน์. 2569. **ระบบแนะนำสินค้าเชิงสนทนาด้วยปัญญาประดิษฐ์.** โครงงานคอมพิวเตอร์. ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น.
อาจารย์ที่ปรึกษา: อ.ดร.พงษ์ศธร จันทร์ยอย

บทคัดย่อ

โครงงานนี้มีวัตถุประสงค์เพื่อเปรียบเทียบสถาปัตยกรรมการสร้างคำตอบโดยอาศัยการค้นคืนแบบมาตรฐานกับแบบที่มีเอเจนต์ตัดสินใจเอง บนระบบแนะนำสินค้าเชิงสนทนาที่รับคำถามได้ทั้งภาษาไทยและภาษาอังกฤษ โดยคลังสินค้าเป็นภาษาอังกฤษทั้งหมด

วิธีดำเนินงานเริ่มจากเตรียมคลังสินค้าจริงจาก Amazon จำนวน 81,264 รายการ สร้างดัชนีค้นหาเชิงความหมายด้วยแบบจำลองฝังเวกเตอร์สองภาษา แล้วพัฒนาสถาปัตยกรรม 3 แบบที่ใช้ส่วนประกอบร่วมกันทั้งหมดและต่างกันเฉพาะชั้นที่แบบจำลองภาษาตัดสินใจเอง เพื่อให้การเปรียบเทียบเปลี่ยนตัวแปรทีละตัว ระบบทั้งหมดประมวลผลบนเครื่องคอมพิวเตอร์ส่วนบุคคลด้วยแบบจำลองภาษาขนาด 8 พันล้านพารามิเตอร์ การประเมินใช้ชุดทดสอบที่สร้างขึ้นเอง 140 คำค้นสองภาษา แบ่งตามสิ่งที่คลังมี และติดเฉลยความตรงด้วยมือตามเกณฑ์มาตรฐาน 4 ระดับ

ผลการทดลองพบว่าสถาปัตยกรรมแบบเอเจนต์ให้คะแนน nDCG@3 สูงกว่าแบบมาตรฐานทั้งสองภาษาและไม่แพ้แม้แต่คำค้นเดียว โดยฝั่งอังกฤษเพิ่มจาก 0.3288 เป็น 0.3564 อย่างมีนัยสำคัญทางสถิติ และฝั่งไทยเพิ่มจาก 0.3165 เป็น 0.3267 อย่างไรก็ตาม ความได้เปรียบทั้งหมดมาจากกลุ่มคำค้นที่คลังไม่มีสินค้าตรงเท่านั้น ส่วนกลุ่มที่คลังมีสินค้าตรงนั้นทุกสถาปัตยกรรมได้คะแนนเท่ากัน นอกจากนี้ยังพบว่าชั้นจัดอันดับเป็นคอขวดที่แท้จริงของระบบ เนื่องจากทำให้สินค้าที่ตรงสูญหายไปร้อยละ 45 ถึง 48 ซึ่งมากกว่าทุกชั้นอื่นรวมกันประมาณ 3.5 เท่า และการเพิ่มสัญญาณนับคำที่ซ้อนกับคำค้นเข้าไปในชั้นนี้ให้ผลดีกว่าการเพิ่มความเป็นเอเจนต์ประมาณ 2 เท่า

ผลที่ได้นำไปใช้เป็นแนวทางเลือกสถาปัตยกรรมสำหรับระบบค้นหาสินค้าได้ คือความเป็นเอเจนต์คุ้มค่าเมื่อคำค้นมีโอกาสหาของไม่เจอ ไม่ใช่ทุกกรณี และโครงงานนี้ได้เผยแพร่ชุดทดสอบพร้อมเฉลยสู่สาธารณะเพื่อให้ผู้อื่นนำไปวัดผลซ้ำได้

คำสำคัญ: ระบบแนะนำสินค้าเชิงสนทนา, การสร้างคำตอบโดยอาศัยการค้นคืน, เอเจนต์อัจฉริยะ, การค้นคืนข้ามภาษา, แบบจำลองภาษาขนาดใหญ่

Sachittha Sinthamdi and Nititorn Khotcharat. 2026. **AI-Based Conversational Product Recommendation System.** Computer Project, Bachelor of Science, Program in Computer Science, College of Computing, Khon Kaen University.
Project Advisor: Pongsathorn Chanyoy, Ph.D.

ABSTRACT

This project aimed to compare a standard retrieval-augmented generation architecture with an agentic one, in which a language model makes decisions at run time, for a conversational product recommendation system that accepts queries in both Thai and English over an English-only product catalogue.

The work began by preparing a real catalogue of 81,264 Amazon products and building a semantic search index with a bilingual embedding model. Three architectures were then developed. All of them share every component and differ only in which layers the language model decides for itself, so that the comparison changes one variable at a time. The entire system runs on a personal computer using an 8-billion-parameter language model, without calling any external service. Evaluation used a purpose-built test collection of 140 queries in both languages, grouped by what the catalogue actually contains, with relevance judgements assigned by hand following a standard four-level scheme.

The results show that the agentic architectures score higher than the standard one in both languages and lose on no query at all. The English score rises from 0.3288 to 0.3564, which is statistically significant, and the Thai score rises from 0.3165 to 0.3267. However, the entire advantage comes from queries for which the catalogue holds no matching product. When the catalogue does hold a match, all three architectures score identically. The study further finds that the ranking layer, not the retrieval or decision layer, is the real bottleneck: it loses 45 to 48 percent of the relevant products, roughly three and a half times more than every other stage combined. Adding a word-overlap signal to that layer yields about twice the gain that the agentic behaviour provides.

These findings give practical guidance for architecture selection, and the test collection with its judgements is released publicly so that others can reproduce the measurements.

Keywords: Conversational Recommender System, Retrieval-Augmented Generation, Agentic RAG, Cross-lingual Retrieval, Large Language Model

กิตติกรรมประกาศ

ข้าพเจ้าขอขอบพระคุณ อาจารย์ที่ปรึกษาโครงงาน ที่ได้กรุณาให้คำแนะนำ คำปรึกษา และข้อเสนอแนะอันเป็นประโยชน์ ตลอดระยะเวลาการดำเนินโครงงานฉบับนี้ โดยเฉพาะข้อเสนอแนะเรื่องการออกแบบการเปรียบเทียบให้เปลี่ยนตัวแปรทีละตัว ซึ่งเป็นจุดที่ทำให้ข้อสรุปของโครงงานมีความหมาย รวมทั้งสละเวลาในการตรวจแก้ไขและให้กำลังใจ จนทำให้โครงงานนี้สำเร็จลุล่วงไปได้ด้วยดี

ขอขอบพระคุณคณาจารย์ในสาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น ทุกท่านที่ได้ถ่ายทอดความรู้ทางวิชาการ ซึ่งเป็นพื้นฐานสำคัญในการศึกษาค้นคว้าและจัดทำโครงงานนี้

ขอขอบคุณผู้จัดทำชุดข้อมูลสาธารณะที่โครงงานนี้นำมาใช้ ทั้งชุดข้อมูลสินค้าและชุดคำค้นมาตรฐาน ซึ่งทำให้การประเมินผลตั้งอยู่บนข้อมูลจริงของผู้ใช้ แทนที่จะเป็นข้อมูลที่สร้างขึ้นเอง

ขอขอบคุณเพื่อนร่วมชั้นและผู้ที่เกี่ยวข้องทุกท่าน ที่ได้ให้ความช่วยเหลือ แนะนำ และแลกเปลี่ยนความคิดเห็น ซึ่งเป็นประโยชน์ต่อการดำเนินงานในหลายด้าน

ท้ายที่สุดนี้ ข้าพเจ้าขอขอบพระคุณบิดา มารดา และครอบครัว ที่ให้การสนับสนุน ส่งเสริม และเป็นกำลังใจ ตลอดระยะเวลาของการศึกษา

ผู้จัดทำ
ศจิษฐา ศีลธรรมดี
นิติธร คชรัตน์

สารบัญ

บทคัดย่อ ก

ABSTRACT ข

กิตติกรรมประกาศ ค

สารบัญ ง

สารบัญภาพ ช

สารบัญตาราง ซ

1 บทนำ 1

1.1 ความเป็นมาและความสำคัญของปัญหา 1
1.2 วัตถุประสงค์ 2
1.3 ขอบเขตและข้อจำกัดของโครงงาน 2
1.3.1 ขอบเขตด้านข้อมูล 2
1.3.2 ขอบเขตด้านระบบที่พัฒนา 2
1.3.3 ขอบเขตด้านการทดลองและการวัดผล 3
1.3.4 ข้อจำกัดของโครงงาน 3
1.4 ประโยชน์ที่คาดว่าจะได้รับ 4

2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง 5

2.1 ทฤษฎีที่เกี่ยวข้อง 5
2.1.1 การสร้างคำตอบโดยอาศัยการค้นคืน 5
2.1.2 การแบ่งประเภทของสถาปัตยกรรม RAG 5
2.1.3 การฝังเวกเตอร์และการค้นคืนเชิงความหมาย 5
2.1.4 การจัดอันดับด้วยการรวมอันดับจากหลายสัญญาณ 5
2.1.5 ตัวชี้วัดคุณภาพการค้นคืน 6
2.1.6 ความซื่อตรงของคำตอบ 6
2.1.7 การสร้างชุดทดสอบและการวัดความน่าเชื่อถือของเฉลย . . . 7
2.1.8 วิธีทางสถิติที่ใช้ทดสอบนัยสำคัญ 7
2.2 งานวิจัยที่เกี่ยวข้อง 7
2.2.1 งานที่วางรากฐานของ RAG 7
2.2.2 งานที่เพิ่มความสามารถตัดสินใจให้ระบบ RAG 7
2.2.3 งานทบทวนวรรณกรรมที่ใช้กำหนดนิยาม 8
2.2.4 ชุดข้อมูลมาตรฐานด้านการค้นหาสินค้า 8

2.2.5 ตารางเปรียบเทียบงานที่เกี่ยวข้อง 8
2.2.6 ช่องว่างของงานวิจัยที่โครงงานนี้เติมเต็ม 8

3 วิธีการดำเนินโครงงาน 10
3.1 ขั้นตอนการดำเนินงาน 10
3.1.1 การรวบรวมข้อมูล (Data Collection) 10
3.1.2 การเตรียมข้อมูล (Data Preprocessing) 10
3.1.3 การสกัดคุณลักษณะ (Feature Extraction) 11
3.1.4 การฝังเวกเตอร์และสร้างดัชนีค้นหา 11
3.1.5 การพัฒนาสถาปัตยกรรมที่นำมาเปรียบเทียบ 11
3.1.6 การสร้างชุดทดสอบและเฉลย 11
3.1.7 การวัดผลและทดสอบนัยสำคัญ 11
3.2 เครื่องมือที่ใช้ในการดำเนินงาน 11
3.2.1 ฮาร์ดแวร์ 11
3.2.2 ซอฟต์แวร์ 12
3.2.3 ขนาดข้อมูลที่ใช้ 12
3.3 แผนการดำเนินงาน 13

4 การวิเคราะห์ ออกแบบและพัฒนาระบบ 14
4.1 การวิเคราะห์และออกแบบสถาปัตยกรรม 14
4.1.1 หลักการออกแบบเพื่อให้การเปรียบเทียบยุติธรรม 14
4.1.2 ชั้นที่แบบจำลองภาษาตัดสินใจเอง 14
4.1.3 ลำดับการทำงานของระบบ 14
4.2 การออกแบบส่วนประกอบของระบบ 15
4.3 การออกแบบชั้นจัดอันดับ 16
4.3.1 ลำดับการทำงานภายในชั้นจัดอันดับ 16
4.3.2 การรวมสัญญาณด้วยการรวมอันดับ 17
4.3.3 เกณฑ์คัดแบบสัมบูรณ์ 17
4.4 การสร้างชุดทดสอบและการติดเฉลย 18
4.4.1 ที่มาของคำค้น 18
4.4.2 การติดเฉลยและการป้องกันอคติ 18
4.4.3 ความเอนเอียงของกองที่ติดเฉลย 18
4.5 ผลการทดลอง 19
4.5.1 ผลรวมทุกตัวชี้วัด 19
4.5.2 การทดสอบนัยสำคัญทางสถิติ 19
4.5.3 ผลแยกตามกลุ่มคำค้น 20
4.6 ข้อค้นพบ 20
4.6.1 ชั้นจัดอันดับเป็นคอขวดของระบบ ไม่ใช่ชั้นค้นคืน 20
4.6.2 สัญญาณที่ขาดไปของชั้นจัดอันดับ 21
4.6.3 ความสามารถที่แท้จริงของการค้นซ้ำ 23
4.7 ผลเชิงลบที่รายงานไว้ 23
4.7.1 ให้เอเจนต์ปรับน้ำหนักของสัญญาณเอง 23
4.7.2 ให้เอเจนต์ระบุว่าเงื่อนไขข้อใดที่ผลลัพธ์ยังไม่ตอบ 23

4.7.3 บังคับให้ค้นซ้ำเมื่อชื่อสินค้าไม่มีคำที่ผู้ใช้ขอ 24
4.7.4 ผลของการถอดกฎดังกล่าวออกเป็นการแลกเปลี่ยน 24

5 สรุปผลการดำเนินงาน **25**
5.1 สรุปผลการดำเนินโครงงาน 25
5.1.1 ผลตามวัตถุประสงค์แต่ละข้อ 25
5.1.2 คำตอบของคำถามวิจัย 25
5.1.3 ข้อค้นพบที่สำคัญที่สุด 26
5.2 ข้อจำกัดของโครงงาน 26
5.3 ปัญหา อุปสรรค และแนวทางแก้ไข 27
5.3.1 การเปรียบเทียบที่เปลี่ยนหลายตัวแปรพร้อมกัน 27
5.3.2 กองที่ติดเฉลยใช้วัดระบบที่เปลี่ยนไปแล้วไม่ได้ 27
5.3.3 การทดสอบที่ผ่านแต่ไม่ครอบคลุมเส้นทางจริง 27
5.3.4 ความเข้าใจผิดเกี่ยวกับความสามารถของการค้นซ้ำ 27
5.4 ข้อเสนอแนะในการพัฒนาต่อไป 28

เอกสารอ้างอิง **29**

ภาคผนวก ก: หน้าจอสาธิตระบบ **33**

ประวัติผู้เขียน **37**

สารบัญภาพ

ภาพที่ 1	เส้นทางข้อมูลสองสายที่มาบรรจบกันที่ขั้นวัดผล	10
ภาพที่ 2	เปรียบเทียบลำดับการทำงาน 9 ขั้นของทั้งสามสถาปัตยกรรม	15
ภาพที่ 3	ลำดับการทำงานของสัญญาณนับคำซ้อน	22
ภาพที่ 4	หน้าจอหลักของระบบสาธิต ส่วนเลือกสถาปัตยกรรมและช่องพิมพ์คำถาม .	33
ภาพที่ 5	ผลการเปรียบเทียบทั้งสามสถาปัตยกรรมด้วยคำถามเดียวกัน	34

สารบัญตาราง

ตารางที่ 1 เปรียบเทียบงานวิจัยที่เกี่ยวข้องกับโครงงานนี้ 8
ตารางที่ 2 รายการฮาร์ดแวร์ที่ใช้ในการดำเนินงาน 12
ตารางที่ 3 รายการซอฟต์แวร์ที่ใช้ในการดำเนินงาน 12
ตารางที่ 4 ขนาดข้อมูลในแต่ละขั้นของการเตรียมข้อมูล 13
ตารางที่ 5 แผนการดำเนินงาน (Gantt Chart) 13
ตารางที่ 6 ชั้นที่แบบจำลองภาษาตัดสินใจเองในแต่ละสถาปัตยกรรม 14
ตารางที่ 7 ส่วนประกอบของระบบและค่าที่ตั้งไว้ 16
ตารางที่ 8 ลำดับขั้นย่อยภายในชั้นจัดอันดับ พร้อมจำนวนที่เหลือจากตัวอย่างการรันจริง 16
ตารางที่ 9 สัญญาณที่ใช้จัดอันดับและน้ำหนัก 17
ตารางที่ 10 องค์ประกอบของชุดทดสอบ 140 คำค้น 18
ตารางที่ 11 ผลการวัดทุกตัวชี้วัด แยกตามสถาปัตยกรรมและภาษา 19
ตารางที่ 12 ผลการทดสอบนัยสำคัญของ A3C และ A3 เทียบกับ A1 19
ตารางที่ 13 ผลแยกตามกลุ่มคำค้นและภาษา 20
ตารางที่ 14 ชั้นที่ทำให้สินค้าที่ดีสูญหาย 20
ตารางที่ 15 ความสามารถของแต่ละสัญญาณในการแยกสินค้าที่ตรงออกจากสินค้าที่ไม่ตรง 21
ตารางที่ 16 ตัวอย่างการนับคำซ้อนสำหรับคำค้น squeaky balls for large dogs . . 22
ตารางที่ 17 ผลของกฎตัดคำสั้นต่อคำค้นที่มีตัวเลขและหน่วย 23
ตารางที่ 18 เปรียบเทียบผลก่อนและหลังถอดกฎบังคับค้นซ้ำ 24
ตารางที่ 19 สรุปผลตามวัตถุประสงค์ 25
ตารางที่ 20 ค่าที่วัดได้จากหน้าจอสาธิตในภาพที่ 5 35

บทที่ 1
บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

ในปัจจุบัน การค้นหาสินค้าบนร้านค้าออนไลน์เป็นกิจกรรมที่ผู้บริโภคทำเป็นประจำ ระบบค้นหาที่ร้านค้าออนไลน์ใช้กันอยู่ส่วนใหญ่ทำงานโดยจับคู่คำที่ผู้ใช้พิมพ์กับคำที่ปรากฏในชื่อสินค้า วิธีนี้ได้ผลดีเมื่อผู้ใช้รู้อยู่แล้วว่าต้องการสินค้าชื่ออะไร แต่ได้ผลไม่ดีเมื่อผู้ใช้บอกความต้องการเป็นภาษาธรรมชาติ เช่น ระบุเงื่อนไขหลายข้อพร้อมกัน บอกงบประมาณ หรือใช้คำเรียกที่ต่างจากคำที่ร้านค้าใช้

แนวทางที่ได้รับความสนใจในระยะหลังคือการนำแบบจำลองภาษาขนาดใหญ่มาช่วยตอบ โดยให้ค้นข้อมูลจากคลังสินค้าก่อนแล้วจึงเขียนคำตอบจากสิ่งที่ค้นได้ เรียกว่าการสร้างคำตอบโดยอาศัยการค้นคืน หรือ Retrieval-Augmented Generation [1] วิธีนี้ทำให้ระบบตอบด้วยข้อมูลสินค้าจริงแทนการแต่งขึ้นเอง

อย่างไรก็ตาม โครงสร้างพื้นฐานของวิธีนี้ทำงานเป็นท่อเส้นตรง คือรับคำถาม ค้นหนึ่งครั้ง แล้วเขียนคำตอบ จุดอ่อนที่ตามมาคือเมื่อการค้นครั้งเดียวนั้นหาของไม่เจอ ระบบไม่มีโอกาสแก้ตัว และยังคงตอบด้วยสินค้าที่ไม่ตรงกับที่ผู้ใช้ขอ ปัญหานี้รุนแรงขึ้นในบริบทของผู้ใช้ชาวไทย เพราะข้อมูลสินค้าในคลังส่วนใหญ่เป็นภาษาอังกฤษ ขณะที่ผู้ใช้พิมพ์คำค้นเป็นภาษาไทย ความคลาดเคลื่อนที่เกิดจากการข้ามภาษาจึงซ้อนทับกับความคลาดเคลื่อนของการค้นอีกชั้นหนึ่ง

เพื่อแก้จุดอ่อนดังกล่าว งานวิจัยจำนวนหนึ่งเสนอให้ระบบตัดสินใจได้เองว่าจะค้นซ้ำหรือไม่ และจะปรับคำค้นอย่างไร [2, 3] แนวทางกลุ่มนี้เรียกรวมว่า Agentic RAG ซึ่งนิยามด้วยการมีชั้นที่แบบจำลองภาษาเป็นผู้ตัดสินใจเองขณะทำงาน ไม่ใช่เพียงทำตามลำดับที่เขียนไว้ล่วงหน้า [4]

ช่องว่างที่พบ คือแม้แนวคิดนี้จะได้รับการยอมรับในทางทฤษฎี แต่หลักฐานเชิงประจักษ์ยังมีข้อจำกัดสามประการ ประการแรก งานที่เสนอสถาปัตยกรรมใหม่มักเปรียบเทียบกับระบบพื้นฐานโดยเปลี่ยนหลายองค์ประกอบพร้อมกัน จึงสรุปไม่ได้ว่าผลที่ดีขึ้นมาจากความสามารถในการตัดสินใจจริงหรือมาจากองค์ประกอบอื่น ประการที่สอง งานเหล่านั้นประเมินบนคำค้นและเอกสารที่เป็นภาษาเดียวกัน ยังไม่มีหลักฐานในสถานการณ์ที่คำค้นกับข้อมูลเป็นคนละภาษา และประการที่สาม งานเหล่านั้นส่วนใหญ่ใช้แบบจำลองภาษาขนาดใหญ่ผ่านบริการภายนอก จึงยังไม่ทราบว่าแบบจำลองขนาดที่ทำงานได้บนเครื่องคอมพิวเตอร์ส่วนบุคคลจะมีความสามารถในการตัดสินใจเพียงพอหรือไม่

ด้วยเหตุนี้ โครงงานนี้จึงมุ่งเปรียบเทียบสถาปัตยกรรมแบบ RAG มาตรฐานกับแบบ Agentic RAG บนระบบแนะนำสินค้าเชิงสนทนาที่รองรับทั้งภาษาไทยและภาษาอังกฤษ โดยออกแบบให้สถาปัตยกรรมที่นำมาเปรียบเทียบใช้ส่วนประกอบร่วมกันทั้งหมดและต่างกันเฉพาะชั้นที่ตัดสินใจ เพื่อให้ตอบได้ว่าความสามารถในการตัดสินใจเองนั้นให้ประโยชน์จริงหรือไม่ และให้ประโยชน์ในสถานการณ์ใด

1.2 วัตถุประสงค์

1) เพื่อ พัฒนา ระบบ แนะนำ สินค้า เชิง สนทนา ที่ รับคำ ถาม ได้ ทั้ง ภาษา ไทย และ ภาษา อังกฤษ บน คลัง สินค้า จริง ที่ เป็น ภาษา อังกฤษ โดย ประมวล ผล บน เครื่อง คอมพิวเตอร์ส่วนบุคคลทั้งหมด

2) เพื่อเปรียบเทียบประสิทธิภาพระหว่างสถาปัตยกรรมแบบ RAG มาตรฐานกับแบบ Agentic RAG ด้วยการออกแบบการทดลองที่เปลี่ยนตัวแปรทีละตัว

3) เพื่อศึกษาว่าความสามารถในการตัดสินใจเองของแบบจำลองภาษาขนาดที่ทำงานได้บนเครื่องส่วนบุคคล ส่งผลต่อคุณภาพการแนะนำสินค้าในสถานการณ์ใดบ้าง

4) เพื่อสร้างและเผยแพร่ชุดทดสอบพร้อมเฉลยสำหรับการค้นหาสินค้าสองภาษา ให้ผู้อื่นนำไปวัดผลซ้ำได้

1.3 ขอบเขตและข้อจำกัดของโครงงาน

1.3.1 ขอบเขตด้านข้อมูล

1) ใช้ข้อมูลสินค้าจริงจากคลัง Amazon Reviews 2023 [5] หลังผ่านการล้างข้อมูลเหลือ 81,264 รายการ ครอบคลุมสินค้าหลายหมวด

2) ข้อมูล สินค้า ทั้งหมด เป็น ภาษา อังกฤษ ไม่มี รายการ ใด ที่ ชื่อ สินค้า เป็น ภาษาไทย

3) ไม่มีการเพิ่มหรือปรับปรุงข้อมูลสินค้าระหว่างการทดลอง คลังข้อมูลถูกตรึงไว้ตลอดการวัดผล

1.3.2 ขอบเขตด้านระบบที่พัฒนา

1) พัฒนาสถาปัตยกรรม 3 แบบเพื่อนำมาเปรียบเทียบ ได้แก่ แบบ RAG มาตรฐาน ที่ไม่มี ชั้น ตัดสินใจ แบบที่แบบ จำลอง ภาษา ตัดสินใจ เฉพาะ การเลือกการกระทำ และแบบที่แบบจำลองภาษาตัดสินใจทั้งการเลือกการกระทำและการค้นซ้ำ

2) ทั้งสาม แบบใช้ส่วนประกอบร่วมกันทั้งหมด ได้แก่ ส่วนความจำ ส่วน แปลภาษา ส่วนค้นคืน ส่วน จัดอันดับ และส่วนเขียนคำตอบ ต่างกัน เฉพาะชั้นที่ตัดสินใจเท่านั้น

3) ระบบ รับคำ ถาม เป็น ข้อความ สนทนา ได้ หลาย รอบ และ จดจำ ความ ต้องการของผู้ใช้ข้ามรอบสนทนา

4) ระบบแนะนำสินค้าครั้งละไม่เกิน 3 รายการ และต้องตอบว่าไม่พบเมื่อคลังไม่มีสินค้าที่ตรงกับที่ขอ

5) ไม่ ได้ พัฒนา ส่วน ติดต่อ ผู้ ใช้ แบบ เว็บ หรือ แอปพลิเคชัน บน มือ ถือ เนื่องจากโครงงานนี้มุ่งตอบคำถามเชิงเปรียบเทียบสถาปัตยกรรม ไม่ใช่การส่งมอบผลิตภัณฑ์

1.3.3 ขอบเขตด้านการทดลองและการวัดผล

1) สร้างชุดทดสอบจำนวน 140 คำค้น โดยยืมข้อความคำค้นจริงของผู้ใช้จากชุดข้อมูลมาตรฐานที่ตีพิมพ์แล้ว [6, 7] และแปลเป็นภาษาไทยคู่กัน

2) แบ่งชุดทดสอบเป็น 3 กลุ่มตามสิ่งที่คลังมี ได้แก่ กลุ่มที่คลังมีสินค้าตรง กลุ่มที่คลังไม่มีสินค้าตรง และกลุ่มที่มีเงื่อนไขงบประมาณ

3) ติดเฉลยความตรงของสินค้าด้วยมือตามเกณฑ์มาตรฐาน 4 ระดับ [6] และติดเฉลยความซื่อตรงของคำตอบตามเกณฑ์ 3 ระดับ

4) วัดผลด้วย nDCG@3 [8] ร่วมกับตัวชี้วัดการตัดสินใจแนะนำหรือปฏิเสธการทำตามงบประมาณ ความซื่อตรงของคำตอบ และต้นทุนด้านเวลา

5) ทดสอบนัยสำคัญทางสถิติด้วยการทดสอบจับคู่แบบสลับเครื่องหมายที่นับครบทุกกรณี [9]

6) ประมวล ผล บน เครื่อง คอมพิวเตอร์ ส่วน บุคคล เครื่อง เดียว ตลอด การ ทดลอง ไม่เรียกใช้บริการแบบจำลองภาษาผ่านเครือข่าย

1.3.4 ข้อจำกัดของโครงงาน

1) แบบจำลองภาษาที่ใช้มีขนาด 8 พันล้านพารามิเตอร์ ซึ่งเป็นขนาดใหญ่ที่สุดที่ทำงานได้บนหน่วยความจำของหน่วยประมวลผลกราฟิกขนาด 8 กิกะไบต์ ผลที่ได้จึงสรุปไปถึงแบบจำลองขนาดใหญ่กว่านี้ไม่ได้

2) คำค้นภาษาไทยในชุดทดสอบได้จากการแปลคำค้นภาษาอังกฤษ ไม่ใช่คำค้นที่ผู้ใช้ชาวไทยพิมพ์ขึ้นเอง ความยากที่เกิดจากการสะกดผิดจึงหายไปบางส่วนเมื่อผ่านการแปล

3) เฉลยความตรงติดโดยผู้วิจัยซึ่งเป็นผู้พัฒนาระบบที่ถูกประเมินเอง ยังไม่มีผู้ติดป้ายอิสระคนที่สองมาติดซ้ำ

4) กองที่ติดเฉลยมาจากสินค้าที่ระบบของโครงงานนี้หยิบขึ้นมาเท่านั้น ระบบอื่นที่หยิบสินค้านอกกองจะถูกประเมินต่ำกว่าความเป็นจริง [10]

5) ตัวหารของ nDCG ใช้ระบบในอุดมคติแทนกองที่ติดเฉลย ค่าที่ได้จึงนำไปเทียบกับงานวิจัยอื่นที่ใช้ตัวหารแบบอื่นโดยตรงไม่ได้

6) ชุดทดสอบไม่ครอบคลุมสถานการณ์ที่คลังมีสินค้าใกล้เคียงแต่ไม่ตรง ซึ่งเป็นสถานการณ์ที่การค้นซ้ำน่าจะได้เปรียบมากที่สุด การประเมินจึงอาจต่ำกว่าประโยชน์จริงของการค้นซ้ำ

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1) ได้ระบบแนะนำสินค้าเชิงสนทนาที่รับคำถามได้สองภาษาบนคลังสินค้าภาษาอังกฤษ และทำงานได้บนเครื่องคอมพิวเตอร์ส่วนบุคคลโดยไม่ต้องพึ่งบริการภายนอก

2) ได้หลักฐานเชิงประจักษ์ว่าความสามารถในการตัดสินใจเองของแบบจำลองภาษาให้ประโยชน์ในสถานการณ์ใด และไม่ให้ประโยชน์ในสถานการณ์ใด ซึ่งนำไปใช้ตัดสินใจเลือกสถาปัตยกรรมในงานอื่นได้

3) ได้ชุดทดสอบการค้นหาสินค้าสองภาษาพร้อมเฉลยที่เผยแพร่สู่สาธารณะ ซึ่งผู้อื่นนำไปวัดผลระบบของตนเองและเทียบกับผลของโครงงานนี้ได้

4) ได้องค์ความรู้เกี่ยวกับข้อจำกัดของแบบจำลองภาษาขนาดที่ทำงานบนเครื่องส่วนบุคคลได้ เมื่อนำมาใช้ในบทบาทผู้ตัดสินใจภายในระบบค้นคืน

บทที่ 2
ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 การสร้างคำตอบโดยอาศัยการค้นคืน

การสร้างคำตอบโดยอาศัยการค้นคืน หรือ Retrieval-Augmented Generation (RAG) เป็นวิธีที่ให้แบบจำลองภาษาตอบคำถามโดยอ้างอิงเอกสารที่ค้นมาได้ แทนที่จะตอบจากความรู้ที่ฝังอยู่ในตัวแบบจำลองเพียงอย่างเดียว [1] วิธีนี้แก้ปัญหาสองข้อพร้อมกัน คือแบบจำลองไม่รู้ข้อมูลที่เกิดขึ้นหลังการฝึก และแบบจำลองมักแต่งข้อมูลขึ้นเองเมื่อไม่รู้คำตอบ

โครงสร้างพื้นฐานของ RAG ทำงานเป็นท่อเส้นตรง คือรับคำถาม ค้นหนึ่งครั้ง แล้วเขียนคำตอบจากสิ่งที่ค้นได้ จุดอ่อนที่ตามมาคือถ้าการค้นครั้งเดียวนั้นหาของไม่เจอ ระบบไม่มีโอกาสแก้ตัว และยังตอบด้วยของที่ไม่ตรงอยู่ดี [11]

2.1.2 การแบ่งประเภทของสถาปัตยกรรม RAG

งานทบทวนวรรณกรรมแบ่งสถาปัตยกรรม RAG ออกเป็นหลายระดับ [12] โดยนับการค้นซ้ำแบบวนรอบ การค้นแบบเรียกตัวเอง และการค้นที่ปรับตามความยากของคำถามว่าอยู่ในกลุ่ม RAG ทั้งหมด เพราะลำดับการทำงานยังถูกกำหนดไว้ล่วงหน้าด้วยโปรแกรม

ส่วน Agentic RAG นิยามด้วยเกณฑ์ที่ต่างออกไป คือต้องมีชั้นที่แบบจำลองภาษาเป็นผู้ตัดสินใจเองขณะทำงาน ไม่ใช่เพียงทำตามลำดับที่เขียนไว้ [4] รูปแบบที่ง่ายที่สุดเรียกว่า single-agent router คือมีตัวแทนหนึ่งตัวทำหน้าที่เลือกว่าจะทำอะไรต่อ เส้นแบ่งนี้สำคัญกับโครงงานนี้ เพราะเป็นเกณฑ์ที่ใช้จัดประเภทให้กับสถาปัตยกรรมทั้งสามแบบที่นำมาเปรียบเทียบ

ข้อสรุปที่ได้จากวรรณกรรม คือการมีลูปค้นซ้ำไม่ได้ทำให้ระบบเป็น Agentic RAG สิ่งที่ทำให้เป็นคือการมีชั้นที่แบบจำลองภาษาตัดสินใจเองขณะทำงาน

2.1.3 การฝังเวกเตอร์และการค้นคืนเชิงความหมาย

การค้นคืนเชิงความหมายแปลงทั้งคำค้นและเอกสารเป็นเวกเตอร์ในปริภูมิเดียวกัน แล้ววัดความใกล้เคียงด้วยค่าโคไซน์ ทำให้ค้นเจอแม้ใช้คำคนละคำกับที่เอกสารใช้ ซึ่งการค้นแบบจับคู่คำตรงตัวทำไม่ได้

โครงงานนี้ใช้แบบจำลองฝังเวกเตอร์ที่รองรับหลายภาษาในแบบจำลองเดียว [13] จึงวางคำค้นภาษาไทยและชื่อสินค้าภาษาอังกฤษไว้ในปริภูมิเดียวกันได้ ส่วนการค้นเวกเตอร์ที่ใกล้ที่สุดในคลังขนาดใหญ่ใช้โครงสร้างดัชนีแบบกราฟลำดับชั้น [14] ซึ่งแลกความแม่นยำสมบูรณ์กับความเร็วที่เพิ่มขึ้นหลายเท่า

2.1.4 การจัดอันดับด้วยการรวมอันดับจากหลายสัญญาณ

เมื่อมีสัญญาณหลายตัวที่บอกว่าสินค้าชิ้นใดควรอยู่อันดับต้น เช่น ความใกล้เชิงความหมาย คะแนนดาว และจำนวนรีวิว การรวมสัญญาณด้วยการบวกค่าดิบทำได้ยาก เพราะ

แต่ละสัญญาณมีหน่วยและช่วงค่าต่างกัน

วิธีรวมอันดับแบบ Reciprocal Rank Fusion [15] แก้ปัญหานี้โดยไม่ใช้ค่าดิบเลย แต่ใช้เฉพาะ**อันดับ**ที่แต่ละสัญญาณจัดให้ แล้วรวมคะแนนตามสมการที่ 1

$$\mathrm{RRF}(d) = \sum_{i \in S} \frac{w_i}{k + r_i(d)} \tag{1}$$

เมื่อ d คือสินค้าที่พิจารณา S คือเซตของสัญญาณทั้งหมด w_i คือน้ำหนักของสัญญาณที่ i $r_i(d)$ คืออันดับของสินค้านั้นตามสัญญาณที่ i และ k คือค่าคงที่ที่ลดอิทธิพลของอันดับต้น ๆ ไม่ให้มากเกินไป

คุณสมบัติที่ต้องเข้าใจคือ RRF ใช้เฉพาะอันดับ จึง**ไม่รับรู้ว่าสัญญาณหนึ่งเหนือกว่าอีกสัญญาณมากเพียงใด** คุณสมบัตินี้มีผลโดยตรงต่อข้อค้นพบของโครงงานนี้

2.1.5 ตัวชี้วัดคุณภาพการค้นคืน

ตัวชี้วัดหลักที่ใช้คือ Normalized Discounted Cumulative Gain (nDCG) [8] ซึ่งให้คะแนนตามความตรงของสิ่งที่ค้นได้ โดยถ่วงน้ำหนักให้อันดับต้นมีค่ามากกว่าอันดับท้าย ตามสมการที่ 2 และ 3

$$\mathrm{DCG@}k = \sum_{i=1}^{k} \frac{g_i}{\log_2(i+1)} \tag{2}$$

$$\mathrm{nDCG@}k = \frac{\mathrm{DCG@}k}{\mathrm{IDCG@}k} \tag{3}$$

เมื่อ g_i คือค่าความตรงของสินค้าที่อันดับ i และ IDCG@k คือค่าของการจัดอันดับที่ดีที่สุดเท่าที่เป็นไปได้ ซึ่งใช้เป็นตัวหารเพื่อให้คะแนนอยู่ในช่วง 0 ถึง 1

ตัวชี้วัดนี้มีข้อจำกัดสำคัญคือ**วัดเฉพาะคุณภาพของสิ่งที่ตอบ แต่วัดการปฏิเสธที่ถูกต้องไม่ได้** ระบบที่ตอบว่าไม่พบสินค้าในกรณีที่คลังไม่มีของจริง จะได้ nDCG เท่ากับศูนย์เช่นเดียวกับระบบที่ตอบของผิด ทั้งที่พฤติกรรมทั้งสองต่างกันโดยสิ้นเชิง โครงงานนี้จึงต้องเพิ่มตัวชี้วัดการตัดสินใจแนะนำหรือปฏิเสธแยกต่างหาก

2.1.6 ความซื่อตรงของคำตอบ

นอกจากคำถามว่าระบบหาของตรงไหม ยังมีคำถามว่าระบบเขียนเกินข้อมูลที่มีอยู่ในมือหรือไม่ ปัญหานี้เรียกรวมว่าการแต่งข้อมูล ซึ่งเป็นปัญหาที่พบทั่วไปในแบบจำลองภาษา [16]

งานวิจัยแบ่งความผิดพลาดเป็นสองชนิด [17] คือ intrinsic ซึ่งเป็นการบิดเบือนข้อมูลที่ให้ไป และ extrinsic ซึ่งเป็นการเติมสิ่งที่ไม่มีอยู่ในข้อมูลเลย หลักที่ใช้ตัดสินคือทุกข้อความในคำตอบต้องมีข้อมูลรองรับ [18] โครงงานนี้ใช้การแบ่งชนิดนี้ในการติดป้ายความซื่อตรงของคำตอบ

2.1.7 การสร้างชุดทดสอบและการวัดความน่าเชื่อถือของเฉลย

การประเมินระบบค้นคืนใช้กรอบ Cranfield ซึ่งประกอบด้วยคลังเอกสาร ชุดคำค้น และเฉลยความตรง [19] การเลือกคู่ที่จะติดเฉลยนิยมใช้วิธี pooling คือรวมสิ่งที่ระบบต่าง ๆ หยิบขึ้นมาเป็นกองเดียวแล้วติดเฉลยครั้งเดียว

ข้อจำกัดที่ต้องระวังคือ pooling bias [10] กล่าวคือกองที่ติดเฉลยย่อมขึ้นกับระบบที่สร้างมันขึ้นมา ระบบใหม่ที่หยิบของนอกกองจะถูกประเมินต่ำกว่าความเป็นจริง ข้อจำกัดนี้เกิดขึ้นจริงในโครงงานนี้เมื่อเปลี่ยนชั้นจัดอันดับ และเป็นเหตุให้ต้องติดเฉลยเพิ่ม

ส่วนความน่าเชื่อถือของเฉลยวัดด้วยค่าความสอดคล้องระหว่างผู้ติดป้าย โดยใช้ weighted kappa [20] ซึ่งลงโทษความต่างมากขึ้นตามระยะห่างของระดับป้าย อ่านผลด้วยช่วงมาตรฐาน [21] และรายงานตามแนวปฏิบัติของงานด้านภาษา [22] ส่วนกระบวนการติดป้ายที่ดีควรเขียนคู่มือก่อน ติดกองนำร่อง แล้วจึงติดทั้งกอง [23]

2.1.8 วิธีทางสถิติที่ใช้ทดสอบนัยสำคัญ

เมื่อเปรียบเทียบระบบสองระบบบนชุดคำค้นเดียวกัน ข้อมูลที่ได้เป็นข้อมูลจับคู่ คือคำค้นเดียวกันถูกวัดด้วยทั้งสองระบบ การทดสอบที่เหมาะสมกับข้อมูลลักษณะนี้และไม่ต้องสมมติว่าข้อมูลแจกแจงปกติ คือการทดสอบแบบสลับเครื่องหมาย [9]

หลักการคือนำผลต่างของแต่ละคำค้นมาสลับเครื่องหมายทุกรูปแบบที่เป็นไปได้ แล้วนับว่ามีกี่รูปแบบที่ให้ผลรวมมากกว่าหรือเท่ากับค่าที่สังเกตได้จริง สัดส่วนนั้นคือค่า p ข้อควรระวังคือเมื่อจำนวนคำค้นที่ให้ผลต่างกันมีน้อย ค่า p จะมีขีดจำกัดล่างที่ไม่สามารถต่ำกว่านั้นได้ เช่น เมื่อมีคำค้นที่ต่างกันเพียง 5 ข้อ ค่า p ต่ำสุดที่เป็นไปได้คือ $2/2^5 = 0.0625$

ส่วนขนาดของชุดทดสอบ งานวิจัยด้านการประเมินแนะนำว่าจำนวนคำค้นมีผลต่อความเสถียรของผลมากกว่าความละเอียดของเฉลย [24, 25]

2.2 งานวิจัยที่เกี่ยวข้อง

2.2.1 งานที่วางรากฐานของ RAG

Lewis และคณะ [1] เสนอสถาปัตยกรรม RAG เป็นครั้งแรก โดยรวมตัวค้นคืนเข้ากับแบบจำลองสร้างข้อความ และแสดงว่าวิธีนี้ให้คำตอบที่ถูกต้องกว่าการใช้แบบจำลองเพียงอย่างเดียวในงานที่ต้องใช้ความรู้ **ส่วนที่คล้ายกับโครงงานนี้** คือใช้โครงค้นแล้วตอบเหมือนกัน **ส่วนที่ต่าง** คืองานนั้นค้นครั้งเดียวและไม่มีชั้นตัดสินใจ ซึ่งในโครงงานนี้ใช้เป็นเส้นฐานเปรียบเทียบ **ข้อจำกัด** คือเมื่อการค้นครั้งเดียวล้มเหลว ระบบไม่มีกลไกแก้ตัว

2.2.2 งานที่เพิ่มความสามารถตัดสินใจให้ระบบ RAG

Jeong และคณะ [2] เสนอวิธีให้ระบบเลือกกลยุทธ์การค้นตามความยากของคำถาม โดยคำถามง่ายไม่ต้องค้น คำถามยากจึงค้นหลายรอบ **ส่วนที่คล้าย** คือมีการตัดสินใจว่าจะค้นหรือไม่ค้น **ส่วนที่ต่าง** คือใช้ตัวจำแนกที่ฝึกมาเฉพาะ ขณะที่โครงงานนี้ใช้แบบจำลองภาษาตัดสินใจโดยตรง **ข้อสังเกตที่นำมาใช้** คืองานนั้นเตือนว่าการค้นวนในคำถามที่ไม่ต้องวนทำให้ผลแย่ลง ซึ่งตรงกับผลเชิงลบที่พบในโครงงานนี้

Yan และคณะ [3] เสนอกลไกตรวจสอบคุณภาพของสิ่งที่ค้นได้ก่อนนำไป

เขียนคำตอบ และแก้ไขเมื่อพบว่าค้นได้ไม่ดี **ส่วนที่คล้าย** คือมีขั้นประเมินคุณภาพผลการค้น **ส่วนที่ต่าง** คืองานนั้นใช้ตัวประเมินแยกที่ฝึกมาเฉพาะ ส่วนโครงงานนี้ใช้เกณฑ์สัมบูรณ์จากคะแนนความใกล้เชิงความหมายร่วมกับจำนวนสินค้าที่ผ่านเกณฑ์

2.2.3 งานทบทวนวรรณกรรมที่ใช้กำหนดนิยาม

Gao และคณะ [12] จัดระบบ RAG เป็นโมดูลที่ประกอบสลับกันได้ และจัดให้การค้นวนรอบอยู่ในกลุ่ม RAG ขณะที่ Singh และคณะ [4] ทบทวนเฉพาะ Agentic RAG และระบุว่าเกณฑ์คือการมีชั้นที่แบบจำลองตัดสินใจเอง **โครงงานนี้ใช้สองงานนี้เป็นเกณฑ์จัดประเภท**ให้กับสถาปัตยกรรมทั้งสามแบบ ไม่ได้ตั้งนิยามขึ้นเอง

2.2.4 ชุดข้อมูลมาตรฐานด้านการค้นหาสินค้า

Reddy และคณะ [6] เผยแพร่ชุดข้อมูลคำค้นสินค้าจริงของผู้ใช้ Amazon พร้อมเกณฑ์ความตรง 4 ระดับ ส่วน Chen และคณะ [7] เผยแพร่ชุดข้อมูลลักษณะเดียวกันจากเว็บขายเฟอร์นิเจอร์ **โครงงานนี้ยืมข้อความคำค้นจากทั้งสองชุด แต่ไม่ได้ยืมเฉลย** เนื่องจากคลังสินค้าเป็นคนละคลังกัน เฉลยของทั้งสองชุดจึงใช้กับคลังของโครงงานนี้ไม่ได้ **ข้อจำกัดร่วมของทั้งสองชุด** คือไม่มีคำค้นภาษาไทย

2.2.5 ตารางเปรียบเทียบงานที่เกี่ยวข้อง

การเปรียบเทียบคุณสมบัติของงานที่เกี่ยวข้องกับโครงงานนี้แสดงดังตารางที่ 1

ตารางที่ 1 เปรียบเทียบงานวิจัยที่เกี่ยวข้องกับโครงงานนี้

คุณสมบัติ	**RAG** [1]	**Adaptive** [2]	**CRAG** [3]	**โครงงานนี้**
ค้นซ้ำได้หลายรอบ	–	✓	✓	✓
แบบจำลองภาษาตัดสินใจเองขณะทำงาน	–	–	–	✓
รองรับคำค้นภาษาไทย	–	–	–	✓
โดเมนสินค้าเพื่อการซื้อขาย	–	–	–	✓
วัดการปฏิเสธเมื่อคลังไม่มีของ	–	–	–	✓
เปลี่ยนตัวแปรทีละตัวในการเปรียบเทียบ	–	–	–	✓
รันบนเครื่องส่วนบุคคลทั้งหมด	–	–	–	✓
เผยแพร่ชุดทดสอบพร้อมเฉลย	✓	✓	✓	✓

2.2.6 ช่องว่างของงานวิจัยที่โครงงานนี้เติมเต็ม

จากการทบทวนงานที่เกี่ยวข้อง พบช่องว่าง 4 ประการ

1) **การเปรียบเทียบที่เปลี่ยนตัวแปรทีละตัว** งานที่เสนอสถาปัตยกรรมใหม่มักเทียบกับ RAG พื้นฐานโดยเปลี่ยนหลายอย่างพร้อมกัน จึงบอกไม่ได้ว่าผลที่ดีขึ้นมาจากส่วนใด โครงงานนี้ออกแบบให้สถาปัตยกรรมที่นำมาเทียบใช้โมดูลร่วมกันทั้งหมด ต่างกันเฉพาะชั้นที่ตัดสินใจ

2) **การประเมินในบริบทสองภาษาที่ข้อมูลเป็นภาษาเดียว** งานที่มีอยู่ประเมินบนคำค้นและเอกสารภาษาเดียวกัน ขณะที่สถานการณ์จริงของผู้ใช้ไทยคือคำค้นเป็นภาษาไทยแต่ข้อมูลสินค้าเป็นภาษาอังกฤษ

3) **การวัดการปฏิเสธที่ถูกต้อง** ตัวชี้วัดมาตรฐานวัดเฉพาะคุณภาพของสิ่งที่ตอบ ไม่ได้ให้เครดิตกับระบบที่ตอบว่าไม่พบเมื่อคลังไม่มีของจริง ซึ่งเป็นพฤติกรรมที่ระบบแนะนำสินค้าต้องทำให้ถูก

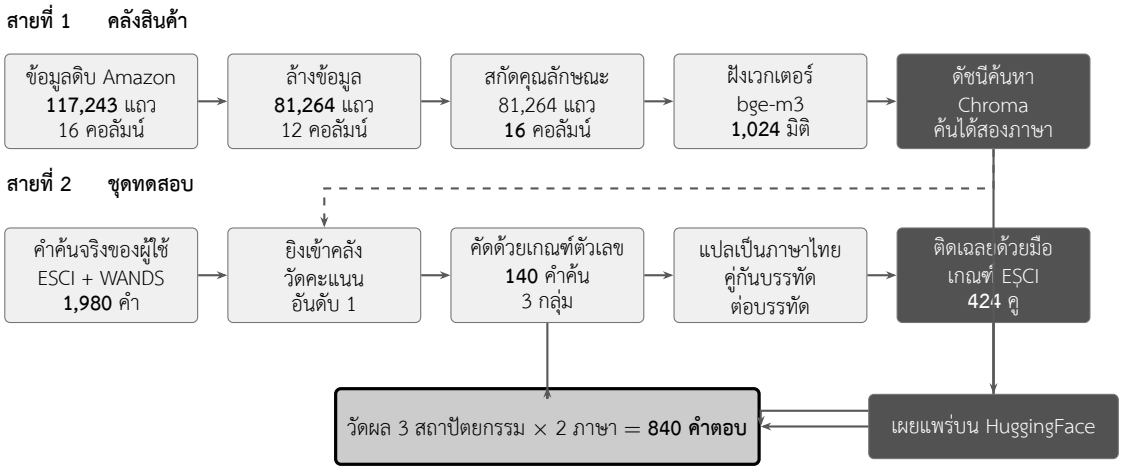
4) **ข้อจำกัดของแบบจำลองขนาดที่รันได้บนเครื่องทั่วไป** งานที่มีอยู่ส่วนใหญ่ใช้แบบจำลองขนาดใหญ่ผ่านบริการภายนอก จึงยังไม่มีหลักฐานว่าความสามารถในการตัดสินใจของแบบจำลองขนาดที่รันบนเครื่องส่วนบุคคลได้นั้นเพียงพอหรือไม่

บทที่ 3
วิธีการดำเนินโครงงาน

โครงงานนี้เป็นงานวิจัยเชิงเปรียบเทียบ จึงดำเนินงานตามลำดับของงานวิจัยด้านการค้นคืนสารสนเทศ คือเตรียมคลังข้อมูล สร้างดัชนีค้นหา พัฒนาสถาปัตยกรรมที่จะนำมาเปรียบเทียบ สร้างชุดทดสอบพร้อมเฉลย แล้วจึงวัดผลและทดสอบนัยสำคัญทางสถิติ

3.1 ขั้นตอนการดำเนินงาน

ทุกขั้นตอนทำด้วยโปรแกรมที่สั่งให้ทำงานซ้ำได้ตั้งแต่ต้นจนจบ ไม่มีขั้นตอนใดแก้ไขข้อมูลด้วยมือ ผู้อื่นจึงทำการทดลองซ้ำแล้วได้ผลเดิม ภาพรวมของเส้นทางข้อมูลทั้งหมดแสดงดังภาพที่ 1



ภาพที่ 1 เส้นทางข้อมูลสองสายที่มาบรรจบกันที่ขั้นวัดผล

3.1.1 การรวบรวมข้อมูล (Data Collection)

ใช้ข้อมูลสินค้าจริงจากคลัง Amazon Reviews 2023 [5] ผ่านชุดข้อมูลที่ผ่านการจัดรูปแบบแล้วบน HuggingFace ได้ข้อมูลตั้งต้น 117,243 แถว 16 คอลัมน์ ครอบคลุมสินค้าหลายหมวด เหตุผลที่ใช้ข้อมูลจริงแทนการสร้างข้อมูลจำลองคือชื่อสินค้าจริงมีลักษณะที่ข้อมูลจำลองไม่มี เช่น ชื่อยาว ตัวย่อทางการค้า และรหัสรุ่นสินค้า ซึ่งเป็นสิ่งที่ระบบค้นคืนต้องรับมือจริง

3.1.2 การเตรียมข้อมูล (Data Preprocessing)

ขั้นล้างข้อมูลใช้ข้อมูลครบทุกหมวดโดยไม่ตัดหมวดใดทิ้ง ดึงคอลัมน์หมวดสินค้าจากชื่อไฟล์ต้นทางเนื่องจากคอลัมน์เดิมขาดหายทั้งหมด และตัดแถวที่ไม่มีราคาออกเพราะโครงงานนี้ต้องประเมินความสามารถในการทำตามงบประมาณ เหลือข้อมูล 81,264 แถว 12 คอลัมน์

3.1.3 การสกัดคุณลักษณะ (Feature Extraction)

ขั้นนี้สร้างคอลัมน์ข้อมูลเพิ่มจากข้อมูลที่มีอยู่ ได้แก่ คะแนนความนิยมแบบเบย์ส คะแนนความคุ้มค่า ข้อความสำหรับฝังเวกเตอร์ และหมวดย่อย รวมเป็น 16 คอลัมน์ คุณลักษณะที่เป็นคุณสมบัติของสินค้า เช่น ยี่ห้อ สี และวัสดุ ไม่ได้แยกเป็นคอลัมน์ แต่รวมไว้ในข้อความที่ใช้ฝังเวกเตอร์ เพื่อให้แบบจำลองภาษาเป็นผู้ตีความแทนการเขียนกฎดึงคำ

3.1.4 การฝังเวกเตอร์และสร้างดัชนีค้นหา

แปลงข้อความสินค้าเป็นเวกเตอร์ด้วยแบบจำลอง `bge-m3` ขนาด 1,024 มิติ ซึ่งรองรับทั้งภาษาไทยและภาษาอังกฤษในแบบจำลองเดียว จากนั้นสร้างดัชนีค้นหาด้วยฐานข้อมูลเวกเตอร์ Chroma โดยเก็บข้อมูลประกอบที่ทุกสถาปัตยกรรมเรียกใช้ร่วมกัน

3.1.5 การพัฒนาสถาปัตยกรรมที่นำมาเปรียบเทียบ

พัฒนาโมดูลการทำงานเป็นชิ้นส่วนที่ใช้ร่วมกันทุกสถาปัตยกรรม ได้แก่ โมดูลความจำ โมดูลวางแผน โมดูลแปลภาษา โมดูลค้นคืน โมดูลจัดอันดับ โมดูลเขียนคำค้นใหม่ และโมดูลสร้างคำตอบ แล้วจึงประกอบเป็นสถาปัตยกรรม 3 แบบที่ต่างกันเฉพาะชั้นที่แบบจำลองภาษาเป็นผู้ตัดสินใจ การออกแบบเช่นนี้ทำให้การเปรียบเทียบยุติธรรม เพราะทุกแบบเรียกใช้โมดูลค้นคืนและโมดูลจัดอันดับตัวเดียวกัน

3.1.6 การสร้างชุดทดสอบและเฉลย

ยืมข้อความคำค้นจริงของผู้ใช้จากชุดข้อมูลมาตรฐานที่ตีพิมพ์แล้ว 2 ชุด นำมายิงเข้าคลังของโครงงานนี้จำนวน 1,980 คำ แล้วคัดด้วยเกณฑ์ตัวเลขเหลือ 140 คำค้น แบ่งเป็น 3 กลุ่มตามสิ่งที่คลังมี จากนั้นติดเฉลยความตรงของสินค้าด้วยมือตามเกณฑ์มาตรฐาน 4 ระดับ ชุดคำค้นถูกล็อกก่อนรันและห้ามแก้หลังเห็นผล

3.1.7 การวัดผลและทดสอบนัยสำคัญ

รันทั้ง 3 สถาปัตยกรรมบนชุดทดสอบเดียวกันทั้งสองภาษา วัดด้วยตัวชี้วัดที่ใช้เฉลยและตัวชี้วัดที่โปรแกรมตรวจเองได้ จากนั้นทดสอบว่าส่วนต่างที่วัดได้แยกจากความบังเอิญได้หรือไม่ ด้วยการทดสอบจับคู่แบบสลับเครื่องหมายที่นับครบทุกกรณี

3.2 เครื่องมือที่ใช้ในการดำเนินงาน

โครงงานนี้ประมวลผลบนเครื่องส่วนบุคคลทั้งหมด ไม่ได้เรียกใช้บริการแบบจำลองภาษาผ่านเครือข่าย เพื่อให้ควบคุมสภาพแวดล้อมการทดลองได้และทำซ้ำได้โดยไม่ขึ้นกับผู้ให้บริการภายนอก

3.2.1 ฮาร์ดแวร์

เครื่องมือด้านฮาร์ดแวร์ที่ใช้แสดงดังตารางที่ 2

ตารางที่ 2 รายการฮาร์ดแวร์ที่ใช้ในการดำเนินงาน

ลำดับ	รายการ	รายละเอียด
1	หน่วยประมวลผลกลาง	Intel Core i5-12400F (6 แกน 12 เธรด)
2	หน่วยความจำหลัก	16 GB
3	หน่วยประมวลผลกราฟิก	NVIDIA GeForce RTX 4060 หน่วยความจำ 8 GB
4	หน่วยเก็บข้อมูล	SSD NVMe ความจุ 500 GB

หน่วยความจำของหน่วยประมวลผลกราฟิกขนาด 8 GB เป็นข้อจำกัดที่กำหนดขนาดของแบบจำลองภาษาที่ใช้ได้ จึงเลือกแบบจำลองขนาด 8 พันล้านพารามิเตอร์ ซึ่งเป็นขนาดใหญ่ที่สุดที่ทำงานได้บนเครื่องนี้โดยไม่ต้องสลับหน่วยความจำ ข้อจำกัดนี้มีผลโดยตรงต่อข้อค้นพบของโครงงาน

3.2.2 ซอฟต์แวร์

เครื่องมือด้านซอฟต์แวร์ที่ใช้แสดงดังตารางที่ 3

ตารางที่ 3 รายการซอฟต์แวร์ที่ใช้ในการดำเนินงาน

ลำดับ	ซอฟต์แวร์	เวอร์ชัน	วัตถุประสงค์
1	Windows 11 Pro	build 26200	ระบบปฏิบัติการ
2	Python	3.12.10	ภาษาที่ใช้พัฒนาทั้งโครงงาน
3	Ollama	0.32.1	รันแบบจำลองภาษาในเครื่อง
4	Typhoon 2 (Llama 3.1)	8B instruct	แบบ จำลอง ภาษา สำหรับ วางแผน แปล และเขียนคำตอบ
5	BGE-M3	–	แบบ จำลอง ฝัง เวก เตอร์ สอง ภาษา 1,024 มิติ
6	Chroma	1.5.9	ฐานข้อมูลเวกเตอร์และดัชนีค้นหา
7	pandas	3.0.6	จัดการข้อมูลแบบตาราง
8	NumPy	2.5.3	คำนวณเชิงตัวเลข
9	huggingface_hub	1.33.0	ดึง ข้อมูล ต้นทาง และ เผย แพร่ ชุด ทดสอบ
10	Visual Studio Code	–	เครื่องมือเขียนโปรแกรม

3.2.3 ขนาดข้อมูลที่ใช้

ขนาดของข้อมูลในแต่ละขั้นแสดงดังตารางที่ 4

ตารางที่ 4 ขนาดข้อมูลในแต่ละขั้นของการเตรียมข้อมูล

ลำดับ	ขั้นตอน	จำนวน	หน่วย
1	ข้อมูลดิบ	117,243	แถว (16 คอลัมน์)
2	หลังล้างข้อมูล	81,264	แถว (12 คอลัมน์)
3	หลังสกัดคุณลักษณะ	81,264	แถว (16 คอลัมน์)
4	เวกเตอร์ที่สร้าง	81,264	ชุด (1,024 มิติ)
5	คำค้นจริงที่นำมาคัด	1,980	คำค้น
6	ชุดทดสอบที่ล็อกแล้ว	140	คำค้น (ภาษาละ 140)
7	เฉลยความตรงที่ใช้คิดผล	424	คู่ (คำค้น, สินค้า)

3.3 แผนการดำเนินงาน

แผนการดำเนินงานตลอดระยะเวลาโครงงานแสดงดังตารางที่ 5

ตารางที่ 5 แผนการดำเนินงาน (Gantt Chart)

ลำดับ	กิจกรรม	ด.1	ด.2	ด.3	ด.4	ด.5	ด.6
1	ทบทวนวรรณกรรม	●	●				
2	รวบรวมและเตรียมข้อมูล	●	●				
3	สร้างดัชนีค้นหา		●				
4	พัฒนา โมดูล ร่วม และ 3 สถาปัตยกรรม			●	●		
5	สร้าง ชุด ทดสอบ และ ติด เฉลย				●	●	
6	รันการทดลองและวัดผล					●	
7	วิเคราะห์ผลและทดสอบนัย สำคัญ					●	●
8	จัดทำรายงานและเผยแพร่ ชุดข้อมูล						●

บทที่ 4

การวิเคราะห์ ออกแบบและพัฒนาระบบ

4.1 การวิเคราะห์และออกแบบสถาปัตยกรรม

4.1.1 หลักการออกแบบเพื่อให้การเปรียบเทียบยุติธรรม

คำถามวิจัยของโครงงานนี้คือ ความสามารถในการตัดสินใจเองของแบบจำลองภาษาให้ประโยชน์จริงหรือไม่ การจะตอบคำถามนี้ได้ การเปรียบเทียบต้องไม่มีตัวแปรอื่นปน หลักการออกแบบจึงกำหนดว่า**ทุกสถาปัตยกรรมต้องใช้ส่วนประกอบชุดเดียวกันทั้งหมด** และต่างกันเฉพาะชั้นที่ตัดสินใจเท่านั้น

หากสถาปัตยกรรมใดมีส่วนค้นคืนหรือส่วนจัดอันดับเป็นของตนเอง ผลที่วัดได้จะบอกไม่ได้ว่ามาจากสถาปัตยกรรมหรือมาจากส่วนประกอบที่เก่งกว่า การออกแบบนี้จึงเป็นเงื่อนไขที่ทำให้ข้อสรุปของโครงงานมีความหมาย

4.1.2 ชั้นที่แบบจำลองภาษาตัดสินใจเอง

ระบบที่พัฒนามีชั้นที่แบบจำลองภาษาตัดสินใจเองได้ 2 ชั้น และความต่างของทั้งสามสถาปัตยกรรมอยู่ที่ชั้นเหล่านี้เท่านั้น ดังตารางที่ 6

ตารางที่ 6 ชั้นที่แบบจำลองภาษาตัดสินใจเองในแต่ละสถาปัตยกรรม

ชั้นที่ตัดสินใจ	**A1**	**A3C**	**A3**
เลือกว่าจะถามกลับ สนทนา หรือค้นหา	–	✓	✓
ตัดสินว่าจะค้นซ้ำอีกรอบหรือไม่	–	กฎในโปรแกรม	✓
จัดเป็นสถาปัตยกรรมแบบ	**RAG**	**Agentic RAG**	**Agentic RAG**

A1 คือ RAG มาตรฐาน ไม่มีชั้นตัดสินใจและค้นเพียงรอบเดียว A3C มีชั้นเลือกการกระทำแต่ให้กฎในโปรแกรมเป็นผู้ตัดสินการค้นซ้ำ ส่วน A3 ให้แบบจำลองภาษาตัดสินทั้งสองชั้น

การแบ่งเช่นนี้ทำให้ได้คู่เปรียบเทียบที่ตอบคนละคำถาม คู่ A1 เทียบ A3C ตอบว่าการเพิ่มความเป็นเอเจนต์เข้าไปช่วยหรือไม่ แต่ต่างกัน 2 ตัวแปรพร้อมกัน ส่วนคู่ A3C เทียบ A3 เป็นคู่เดียวที่**เปลี่ยนตัวแปรทีละตัวอย่างแท้จริง** คือตอบว่าควรขยายขอบเขตการตัดสินใจของเอเจนต์ไปถึงการคุมการค้นซ้ำด้วยหรือไม่

4.1.3 ลำดับการทำงานของระบบ

ลำดับการทำงานเต็มรูปของ A3 มี 9 ขั้น โดย A3C ตัดขั้นที่ 7 ออกแล้วใช้กฎในโปรแกรมแทน ส่วน A1 ตัดทั้งขั้นที่ 2 และขั้นที่ 7 ถึง 8 ออก ดังนี้

1) ปรับปรุงโปรไฟล์ความต้องการของผู้ใช้จากบทสนทนาที่ผ่านมา

2) เลือกการกระทำของรอบนี้ ระหว่างถามกลับ สนทนา หรือค้นหา

3) ประกอบคำค้นจากโปรไฟล์ความต้องการ

4) แปลคำค้นเป็นภาษาอังกฤษหากผู้ใช้ถามเป็นภาษาไทย

5) ค้นในคลังสินค้าโดยดึงผู้เข้าชิง 100 รายการ

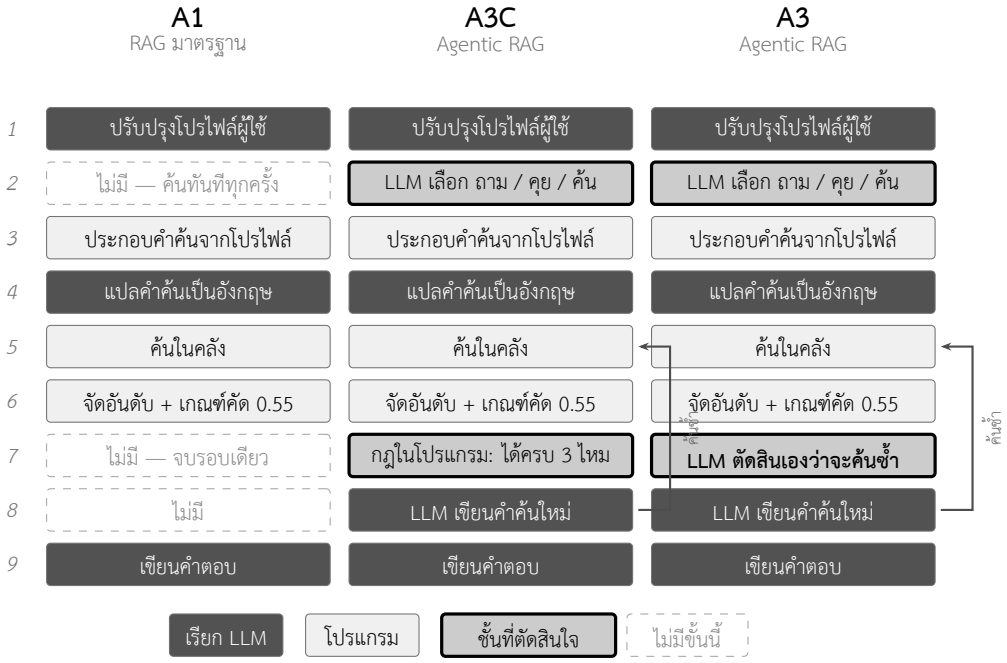
6) จัดอันดับผู้เข้าชิงและคัดด้วยเกณฑ์สัมบูรณ์

7) ตัดสินว่าจะค้นซ้ำอีกรอบหรือไม่

8) เขียนคำค้นใหม่สำหรับรอบถัดไป

9) เขียนคำตอบให้ผู้ใช้จากสินค้าที่เลือกได้

การเปรียบเทียบลำดับการทำงานของทั้งสามสถาปัตยกรรมแบบวางเคียงกัน แสดงดังภาพที่ 2 ซึ่งทำให้เห็นว่าชั้นที่ต่างกันมีเพียงขั้นที่ 2 และขั้นที่ 7 เท่านั้น



ภาพที่ 2 เปรียบเทียบลำดับการทำงาน 9 ขั้นของทั้งสามสถาปัตยกรรม

ขั้นที่ 2 มีผลสำคัญคือ หากเลือกถามกลับหรือสนทนา ระบบจะตอบทันที โดย**ไม่ค้นเลย** และกำหนดเพดานการค้นซ้ำไว้ที่ 2 รอบทั้ง A3C และ A3

4.2 การออกแบบส่วนประกอบของระบบ

ส่วนประกอบทั้งหมดใช้ร่วมกันทุกสถาปัตยกรรม ดังตารางที่ 7

ตารางที่ 7 ส่วนประกอบของระบบและค่าที่ตั้งไว้

ส่วนประกอบ	หน้าที่	ค่าที่ตั้งไว้	A1	A3C
ความจำ	จดจำความต้องการข้ามรอบสนทนาเป็นโปรไฟล์ 9 ช่องที่สะสมขึ้นเรื่อย ๆ	อ่าน ย้อน หลัง 4 รอบ ขยายงบได้ไม่เกิน 2 ครั้ง	✓	✓
วางแผน	เลือกการกระทำของรอบนี้	ถาม กลับ ได้ ไม่ เกิน 2 ครั้ง มี ทาง สำรอง เป็น กฎเสมอ	–	✓
แปลภาษา	แปล คำ ค้น ไทย เป็น อังกฤษ ก่อนค้น	ค่าความสุ่มเป็นศูนย์ จำคำแปลไว้ไม่เรียกซ้ำ	✓	✓
ค้นคืน	ค้นผู้เข้าชิงจากคลัง	ดึง 100 รายการต่อการค้นหนึ่งครั้ง	✓	✓
จัดอันดับ	จัด อันดับ และ คัด ด้วย เกณฑ์สัมบูรณ์	ส่งต่อ 3 รายการ เกณฑ์คัด 0.55	✓	✓
เขียนคำค้นใหม่	สร้างคำค้นสำหรับรอบถัดไป	ใช้แบบจำลองภาษา ไม่ใช้กฎตัดคำ	–	✓
สร้างคำตอบ	เขียนคำตอบให้ผู้ใช้	ค่าความสุ่มเป็นศูนย์ ส่ง เฉพาะ ข้อ เท็จ จริง จาก คลัง	✓	✓

ส่วนเขียนคำค้นใหม่เลือกใช้แบบจำลองภาษาแทนการเขียนกฎ เนื่องจากรุ่นแรกของระบบใช้กฎตัดคำขยายออกทีละชั้น แล้วพบว่า**กฎตัดชื่อสินค้าทิ้ง** ทำให้คำค้นรอบถัดไปกว้างกว่าเดิมและได้สินค้าที่ผิดมากขึ้น

4.3 การออกแบบชั้นจัดอันดับ

4.3.1 ลำดับการทำงานภายในชั้นจัดอันดับ

ชั้นจัดอันดับรับผู้เข้าชิง 100 รายการจากชั้นค้นคืน แล้วทำงาน 4 ขั้นย่อยตามลำดับ ดังตารางที่ 8

ตารางที่ 8 ลำดับขั้นย่อยภายในชั้นจัดอันดับ พร้อมจำนวนที่เหลือจากตัวอย่างการรันจริง

ขั้นย่อย	การทำงาน	จำนวนที่เหลือ
1	ตัดทิ้งตามเงื่อนไขที่ผู้ใช้ระบุเอง เช่น ราคาเกินงบ หรือแบรนด์ที่ผู้ใช้ปฏิเสธ	100
2	คัดด้วยเกณฑ์สัมบูรณ์ 0.55 โดยใช้คะแนนความใกล้เชิงความหมายเพียงอย่างเดียว	73
3	**จัดอันดับด้วย 5 สัญญาณ รวมถึงการนับคำซ้อน**	73
4	หยิบ 3 รายการแรก โดยเลี่ยงการหยิบจากร้านค้าเดียวกันซ้ำ	3

ประเด็นที่ต้องเข้าใจให้ตรงคือการนับคำซ้อนไม่ได้ทำหน้าที่คัดสินค้าทิ้ง สัญญาณนี้ทำงานที่ขั้นย่อยที่ 3 ซึ่งอยู่หลังการคัดด้วยเกณฑ์สัมบูรณ์แล้ว หน้าที่ของมันคือเรียง

ลำดับสินค้าที่ผ่านเกณฑ์มาแล้วเท่านั้น สินค้าที่ได้คะแนนการนับคำซ้อนเป็นศูนย์จึงยังอยู่ในกองเพียงแต่ถูกจัดไปอยู่อันดับท้าย

การแยกหน้าที่เช่นนี้จำเป็น เพราะการคัดว่าดีพอหรือยังต้องใช้เกณฑ์สัมบูรณ์ ส่วนการจัดอันดับเป็นการเปรียบเทียบกันเองภายในกอง ถ้านำการนับคำซ้อนไปใช้เป็นเกณฑ์คัดสินค้าที่คลังเรียกด้วยคำอื่นจะถูกตัดทิ้งทั้งที่ตรงกับความต้องการ ซึ่งเป็นข้อผิดพลาดที่พบจริงและรายงานไว้ในหัวข้อผลเชิงลบ

ข้อความที่นำมานับคำซ้อนคือคำค้นหลังผ่านขั้นแปลภาษาแล้ว ไม่ใช่ข้อความที่ผู้ใช้พิมพ์โดยตรง ฝั่งภาษาไทยจึงได้รับผลกระทบจากความคลาดเคลื่อนของขั้นแปลอย่างหลีกเลี่ยงไม่ได้

นอกจากนี้ ชั้นจัดอันดับถูกเรียกใช้ทุกครั้งที่มีการค้น ไม่ใช่เพียงครั้งเดียวต่อหนึ่งคำถาม เมื่อการค้นซ้ำทำงาน ผู้เข้าชิงชุดใหม่จะถูกจัดอันดับใหม่ทั้งหมด และชั้นนี้เปิดช่องให้เปลี่ยนน้ำหนักของการนับคำซ้อนขณะทำงานได้ ซึ่งเป็นช่องทางที่ใช้ทดลองให้เอเจนต์ปรับน้ำหนักเอง และพบว่าไม่ได้ผล

4.3.2 การรวมสัญญาณด้วยการรวมอันดับ

ชั้นจัดอันดับรวมสัญญาณหลายตัวด้วยวิธีรวมอันดับตามสมการที่ 1 โดยใช้ค่าคงที่ $k = 60$ สัญญาณและน้ำหนักที่ใช้แสดงดังตารางที่ 9

ตารางที่ 9 สัญญาณที่ใช้จัดอันดับและน้ำหนัก

ลำดับ	สัญญาณ	น้ำหนัก	เหตุผล
1	ความใกล้เชิงความหมาย	3	สัญญาณหลักที่บอกความตรงของเนื้อหา
2	คะแนนดาวเฉลี่ย	1	คุณภาพสินค้าในสายตาผู้ซื้อ
3	จำนวนรีวิว	1	กันสินค้า 5 ดาวรีวิวเดียวชนะสินค้า 4.8 ดาวพันรีวิว
4	ความตรงของหมวดสินค้า	1	ตรงกับหมวดที่ผู้ใช้ระบุในโปรไฟล์หรือไม่
5	**จำนวนคำที่ซ้อนกับคำค้น**	**6**	**สัญญาณ ที่ เพิ่ม เข้า มา ภาย หลัง** จับ คำ เงื่อนไขเฉพาะที่สัญญาณอื่นจับไม่ได้

4.3.3 เกณฑ์คัดแบบสัมบูรณ์

ชั้นจัดอันดับคืนค่า 3 อย่าง คือรายการที่เลือกแล้ว รายการทั้งหมดที่ผ่านเกณฑ์พร้อมเหตุผล และ**จำนวนรายการที่ผ่านเกณฑ์** ค่าสุดท้ายนี้เป็นสิ่งที่การค้นซ้ำใช้ตัดสินใจ

เหตุผลที่ต้องมีเกณฑ์สัมบูรณ์แยกจากการจัดอันดับคือ**อันดับเป็นการเปรียบเทียบของในกองเดียวกัน แต่คำถามว่าดีพอหรือยังต้องใช้เกณฑ์สัมบูรณ์** สินค้าที่แย่ที่สุดใน 100 รายการก็ยังได้อันดับที่ 100 อยู่ดี การจัดอันดับจึงไม่เคยบอกได้ว่าทั้งกองไม่ตรงเลย

ค่าเกณฑ์คัดกำหนดไว้ที่ 0.55 ซึ่งได้จากการสร้างกองคำค้นแยกต่างหากที่รู้คำตอบล่วงหน้าว่าควรผ่านหรือควรตก แล้วหาค่าที่แยกสองกองได้ดีที่สุด กองนี้แยกจากชุดทดสอบที่ใช้รายงานผลเพื่อไม่ให้เกิดการปรับค่าบนข้อมูลที่ใช้วัดผล

4.4 การสร้างชุดทดสอบและการติดเฉลย

4.4.1 ที่มาของคำค้น

ชุดทดสอบสร้างจากคำค้นจริงของผู้ใช้ที่ยืมมาจากชุดข้อมูลมาตรฐาน 2 ชุด [6, 7] นำมายิงเข้าคลังของโครงงานนี้จำนวน 1,980 คำ แล้วคัดด้วยเกณฑ์ตัวเลขเหลือ 140 คำค้น ดังตารางที่ 10

ตารางที่ 10 องค์ประกอบของชุดทดสอบ 140 คำค้น

กลุ่ม	จำนวน	เกณฑ์ที่ใช้คัด	คำตอบที่ถูก
คลังมีสินค้าตรง	50	คะแนน อันดับ 1 ไม่ ต่ำ กว่า 0.50 และ ผ่าน เกณฑ์ คัด อย่าง น้อย 3 รายการ	แนะนำ สินค้า 3 รายการที่ตรง
คลังไม่มีสินค้าตรง	60	คะแนนอันดับ 1 ต่ำกว่า 0.47	ตอบว่าไม่พบ
มีเงื่อนไขงบประมาณ	30	นำคำค้นกลุ่มแรกมาเติมเพดานราคา	แนะนำสินค้าที่ไม่เกินงบ

เหตุผลที่ไม่เขียนคำค้นขึ้นเองคือได้ทดลองเขียนเองแล้ว 2 รอบ รวม 76 คำ แต่**ได้คำค้นชั้นยาก 0 คำทั้งสองรอบ** เพราะผู้เขียนไม่รู้รหัสอะไหล่จริง ศัพท์เฉพาะทาง และคำที่ผู้ใช้จริงสะกดผิด ส่วนเหตุผลที่ไม่ยืมเฉลยของชุดข้อมูลต้นทางมาด้วยคือคลังสินค้าเป็นคนละคลังกัน โดยคลังต้นทางซ้อนทับคลังของโครงงานนี้เพียง 17 จาก 856,238 รายการเมื่อเทียบด้วยรหัสสินค้า เฉลยของต้นทางจึงใช้ไม่ได้

4.4.2 การติดเฉลยและการป้องกันอคติ

เฉลยความตรงติดตามเกณฑ์ 4 ระดับ [6] คือตรงเป๊ะ ใช้แทนกันได้ ของเสริม และไม่เกี่ยว โดยผู้วิจัยติดเองทั้งหมด เฉลยที่ใช้คิดตัวเลขในรายงานนี้มีจำนวน 424 คู่

มาตรการป้องกันอคติที่ใช้มี 3 ข้อ

1) **ปิดตาผู้ติดป้าย** ไฟล์เฉลยไม่ระบุว่าสถาปัตยกรรมใดเป็นผู้หยิบสินค้ารายการนั้นขึ้นมา ไม่มีคอลัมน์รอบ อันดับ หรือคะแนน และเรียงลำดับแถวด้วยค่าแฮชคงที่ หากผู้ติดป้ายรู้ว่าสินค้ามาจากสถาปัตยกรรมใด เฉลยย่อมเอนไปตามความคาดหวังว่าแบบใดควรชนะ ซึ่งเป็นสิ่งที่โครงงานนี้กำลังวัดอยู่พอดี

2) **ล็อกชุดคำค้นก่อนรัน** และห้ามแก้หลังเห็นผล

3) **แยกกองพัฒนาออกจากกองวัดผล** คำค้นที่ใช้เขียนและปรับคำสั่งของแบบจำลองห้ามนำมาใช้รายงานผล

4.4.3 ความเอนเอียงของกองที่ติดเฉลย

เมื่อเปลี่ยนชั้นจัดอันดับ พบว่าคำค้นเดิมและกองผู้เข้าชิงเดิม แต่**สามอันดับแรกเปลี่ยนไปถึง 51 จาก 80 คำค้น** สินค้าที่โผล่ขึ้นมาใหม่ยังไม่มีเฉลย และวิธีคิดตัวชี้วัดตัดคำค้นที่เฉลยไม่ครบทิ้งทั้งข้อ ผลคือชุดคำค้นที่เทียบได้ครบทั้งสามสถาปัตยกรรมเหลือเพียง 21 จาก

50 คำ และใน 21 คำนั้นมี 19 คำที่ทุกสถาปัตยกรรมให้ผลเหมือนกันทุกประการ กล่าวคือ**เหลือเฉพาะคำค้นที่ไม่มีอะไรเปลี่ยน จึงวัดอะไรไม่ได้เลย**

ปรากฏการณ์นี้คือความเอนเอียงของกองที่ติดเฉลย [10] ทางแก้คือติดเฉลยเพิ่มสำหรับสินค้าที่โผลใหม่ ซึ่งได้ดำเนินการแล้วจนชุดคำค้นที่เทียบได้ครบกลับมาเป็น 140 จาก 140 คำ

4.5 ผลการทดลอง

4.5.1 ผลรวมทุกตัวชี้วัด

ผลการวัดทั้งหมดได้จากการรัน 3 สถาปัตยกรรม 2 ภาษา ภาษาละ 1 รอบ รวม 840 คำตอบ ไม่มีข้อใดทำงานผิดพลาด แสดงดังตารางที่ 11

ตารางที่ 11 ผลการวัดทุกตัวชี้วัด แยกตามสถาปัตยกรรมและภาษา

ตัวชี้วัด	**A1 อ.**	**A3C อ.**	**A3 อ.**	**A1 ท.**	**A3C ท.**	**A3 ท.**
nDCG@3 ภาพรวม 140 คำ	0.3288	**0.3564**	**0.3564**	0.3165	**0.3267**	**0.3267**
nDCG@3 คลังมีของ	0.594	0.594	0.594	0.545	**0.549**	**0.549**
nDCG@3 มีเงื่อนไขราคา	0.544	**0.549**	**0.549**	0.473	**0.492**	**0.492**
nDCG@3 คลังไม่มีของ	0.000	**0.062**	**0.062**	0.048	**0.059**	**0.059**
P@3 ตรงหรือใช้แทนได้	64.0%	64.0%	64.0%	55.3%	55.3%	55.3%
ได้สินค้าครบ 3 รายการ	79	**86**	**86**	78	**83**	**83**
ปฏิเสธถูกเมื่อคลังไม่มีของ	**60/60**	50/60	50/60	**55/60**	51/60	51/60
ตัดสินถูกเมื่อนับสองทิศ	54/60	**56/60**	**56/60**	58/60	58/60	58/60
จำนวนครั้งที่เรียกแบบจำลอง	**1.56**	3.36	4.68	**2.06**	3.86	5.19
เวลาต่อข้อ (วินาที)	**7.5**	14.2	19.6	**9.6**	16.0	21.3

หมายเหตุสำคัญเรื่องการอ่านตารางนี้ แถวปฏิเสธถูกนับการปฏิเสธทุกครั้งว่าถูก จึงให้คะแนนเต็มกับสถาปัตยกรรมที่ปฏิเสธทุกอย่าง ส่วนแถวตัดสินถูกนับทั้งสองทิศ คือ ปฏิเสธถูกเมื่อคลังไม่มีของ บวกกับแนะนำได้เมื่อคลังมีของ เมื่อนับแบบนี้ A1 ฝั่งอังกฤษตกจาก 60/60 เหลือ 54/60 ซึ่งแสดงว่าคะแนนเต็มเดิมมาจากการปฏิเสธทุกอย่าง ไม่ใช่การตัดสินที่ถูกต้อง

4.5.2 การทดสอบนัยสำคัญทางสถิติ

ผลการทดสอบจับคู่แบบสลับเครื่องหมายที่นับครบทุกกรณีแสดงดังตารางที่ 12

ตารางที่ 12 ผลการทดสอบนัยสำคัญของ A3C และ A3 เทียบกับ A1

ภาษา	**A1**	**A3C และ A3**	**ดีขึ้น · แย่ลง**	**ค่า p**
อังกฤษ	0.3288	**0.3564**	**8 · 0**	**0.0078**
ไทย	0.3165	**0.3267**	**5 · 0**	0.0625

ฝั่งอังกฤษมีนัยสำคัญที่ระดับ 0.01 ส่วนฝั่งไทยได้ค่า 0.0625 ซึ่ง**เป็นค่าต่ำสุดที่เป็นไปได้เมื่อมีคำค้นที่ให้ผลต่างกันเพียง 5 ข้อ** เนื่องจาก $2/2^5 = 0.0625$ จึงเป็นข้อจำกัดของ

จำนวนข้อ ไม่ใช่สัญญาณว่าผลอ่อน ประเด็นสำคัญคือ**ทั้งสองภาษาไม่มีคำค้นใดที่สถาปัตยกรรมแบบเอเจนต์แพ้เลยแม้แต่ข้อเดียว**

4.5.3 ผลแยกตามกลุ่มคำค้น

ผลแยกตามกลุ่มแสดงดังตารางที่ 13 ซึ่งชี้ว่าความได้เปรียบของสถาปัตยกรรมแบบเอเจนต์กระจุกอยู่ที่กลุ่มเดียว

ตารางที่ 13 ผลแยกตามกลุ่มคำค้นและภาษา

กลุ่ม	ภาษา	A1	A3C และ A3	ดีขึ้น · แย่ลง	ค่า p
คลังมีของ	อังกฤษ	0.5944	0.5944	0 · 0	1.0000
คลังมีของ	ไทย	0.5454	0.5490	1 · 0	1.0000
มีเงื่อนไขราคา	อังกฤษ	0.5438	0.5490	1 · 0	1.0000
มีเงื่อนไขราคา	ไทย	0.4726	0.4922	2 · 0	0.5000
คลังไม่มีของ	**อังกฤษ**	**0.0000**	**0.0617**	**7 · 0**	**0.0156**
คลังไม่มีของ	ไทย	0.0477	0.0588	2 · 0	0.5000

ข้อสังเกตที่สำคัญที่สุดจากตารางนี้ คือในกลุ่มที่คลังมีสินค้าตรง ทั้งสามสถาปัตยกรรมได้คะแนนเท่ากันทุกทศนิยมในฝั่งอังกฤษ แปลว่าเมื่อการค้นรอบแรกได้ผลดีอยู่แล้ว ชั้นตัดสินใจไม่ได้สร้างความต่างใด ๆ ความได้เปรียบทั้งหมดมาจากกลุ่มที่คลังไม่มีสินค้าตรง ซึ่งการค้นซ้ำทำให้ระบบหาสินค้าที่ใช้แทนกันได้เจอ ในคำค้นที่ A1 ตอบว่าไม่พบ

สถิติการทำงานของการค้นซ้ำสนับสนุนข้อสังเกตนี้ คือการค้นซ้ำ**ไม่ทำงานเลยเมื่อคลังมีของ** และทำงาน 36 เปอร์เซ็นต์ฝั่งอังกฤษกับ 38 เปอร์เซ็นต์ฝั่งไทย ซึ่งอยู่ในกลุ่มที่คลังไม่มีของทั้งหมด

4.6 ข้อค้นพบ

4.6.1 ชั้นจัดอันดับเป็นคอขวดของระบบ ไม่ใช่ชั้นค้นคืน

เพื่อหาว่าสินค้าที่ดีสูญหายไปที่ขั้นใด ได้ตรวจสอบทุกขั้นของระบบในกลุ่มที่คลังมีสินค้า โดยนับสินค้าที่มีเฉลยระดับใช้แทนได้ขึ้นไปว่าตกหล่นที่ชั้นใด ผลแสดงดังตารางที่ 14

ตารางที่ 14 ชั้นที่ทำให้สินค้าที่ดีสูญหาย

ชั้นที่สูญหาย	ไทย	อังกฤษ
ค้นไม่เจอใน 100 อันดับแรก	16 (5.9%)	18 (6.6%)
ตกที่กฎกรองทิ้ง	0	0
ตกที่เกณฑ์คัด	16 (5.9%)	17 (6.2%)
ตกที่ชั้นจัดอันดับ	**131 (48.2%)**	**123 (45.2%)**
ตกที่การตัดร้านค้าซ้ำ	3	2

ชั้นจัดอันดับทำสินค้าที่ดีสูญหายมากกว่าทุกชั้นอื่นรวมกันประมาณ 3.5

เท่า และสูญหายในสัดส่วนใกล้เคียงกันทั้งสองภาษา ข้อค้นพบนี้เปลี่ยนทิศทางการพัฒนา เพราะก่อนหน้านี้ความพยายามปรับปรุงมุ่งไปที่ชั้นค้นคืนและชั้นตัดสินใจ ซึ่งไม่ใช่จุดที่เสียหายจริง

4.6.2 สัญญาณที่ขาดไปของชั้นจัดอันดับ

เมื่อตรวจว่าสัญญาณเดิม 4 ตัวแยกสินค้าที่ตรงเป๊ะออกจากสินค้าที่ไม่เกี่ยวได้หรือไม่ พบว่าแยกไม่ได้ ดังตารางที่ 15

ตารางที่ 15 ความสามารถของแต่ละสัญญาณในการแยกสินค้าที่ตรงออกจากสินค้าที่ไม่ตรง

สัญญาณ	**ผลการแยก**
ความใกล้เชิงความหมาย	แยกไม่ได้ คะแนนเฉลี่ย 0.639 เทียบ 0.591 แทบไม่ต่างกัน
ดาว จำนวนรีวิว และหมวดสินค้า	แยกไม่ได้ เพราะไม่ได้วัดความตรงเลย
จำนวนคำที่ซ้อนกับคำค้น	**แยกได้ 0.667 เทียบ 0.333**

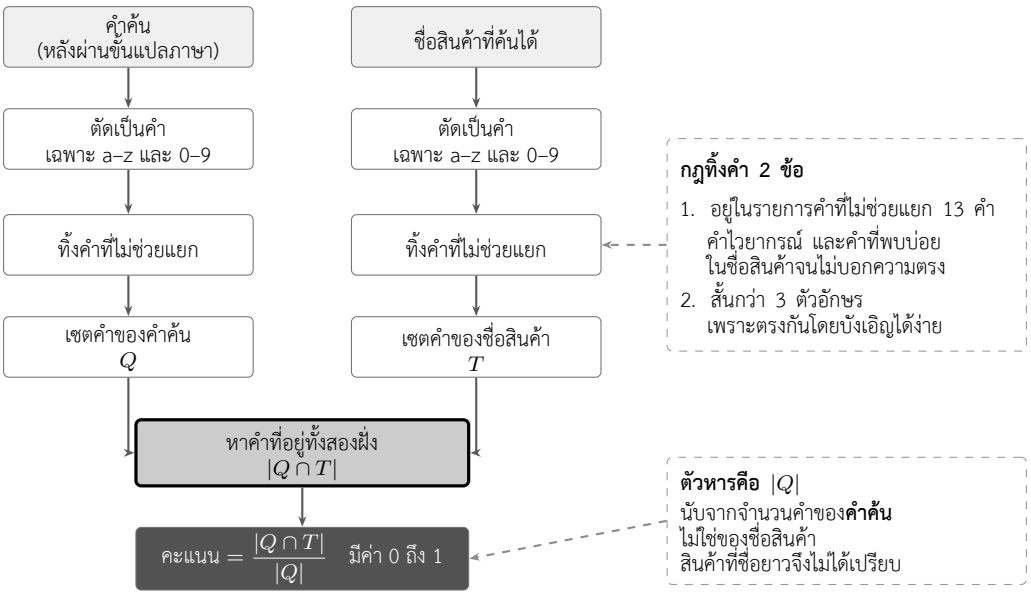
สาเหตุที่คะแนนความใกล้เชิงความหมายแยกไม่ได้ เกิดจากเวกเตอร์ของข้อความทั้งหมดกระจุกอยู่ในกรวยแคบ ซึ่งเป็นคุณสมบัติที่พบในแบบจำลองภาษาโดยทั่วไป [26] การวัดพบว่าข้อความที่ไม่เกี่ยวข้องกันเลยยังได้คะแนนประมาณ 0.457 ไม่ใช่ศูนย์ ช่วงค่าที่ใช้งานได้จริงจึงแคบเพียง 0.42 ถึง 0.75

เมื่อเพิ่มการนับคำที่ซ้อนกันเป็นสัญญาณที่ 5 ได้ผลเพิ่มขึ้น **4.5 จุด** บนกองที่จำกัดเฉพาะสินค้าที่มีเฉลย ที่ระดับนัยสำคัญ $p = 0.0005$ และยืนยันผลแบบตลอดสายที่ A1 ฝั่งอังกฤษได้เพิ่มขึ้น 3.5 จุดในกลุ่มคลังมีของ และ 3.4 จุดในกลุ่มมีเงื่อนไขราคา ซึ่งเป็นผลที่**มากกว่าผลที่ความเป็นเอเจนต์ให้ประมาณ 2 เท่า**

วิธีนับคำซ้อนและกฎตัดคำ

การนับทำเป็น 5 ขั้น คือตัดข้อความทั้งของคำค้นและของชื่อสินค้าให้เป็นคำ ทิ้งคำที่ไม่ช่วยแยก เอาเฉพาะคำที่ไม่ซ้ำ นับว่าคำในคำค้นปรากฏในชื่อสินค้ากี่คำ แล้วหารด้วยจำนวนคำในคำค้น ได้ค่าระหว่าง 0 ถึง 1 ตัวหารเป็นจำนวนคำของคำค้น ไม่ใช่ของชื่อสินค้า สินค้าที่มีชื่อยาวจึงไม่ได้เปรียบ

ลำดับการทำงานทั้งหมดแสดงดังภาพที่ 3



ภาพที่ 3 ลำดับการทำงานของสัญญาณนับคำซ้อน

ตัวอย่างการคำนวณแสดงดังตารางที่ 16

ตารางที่ 16 ตัวอย่างการนับคำซ้อนสำหรับคำค้น squeaky balls for large dogs

ขั้น	ผลลัพธ์
1	ตัดคำค้นเป็นคำ ได้ squeaky · balls · for · large · dogs
2	ทิ้งคำที่ไม่ช่วยแยก เหลือ squeaky · balls · large · dogs รวม 4 คำ
3	ชื่อสินค้า XL Thick Dog Rope Toy for Large Breed Aggressive Chewers
4	คำที่ปรากฏในชื่อสินค้า มี large เพียงคำเดียว
5	คะแนน $= 1 \div 4 = 0.250$

แนวคิดของการวัดความตรงจากคำที่ตรงกันเป็นรากฐานของการค้นคืนแบบจับคู่คำ ซึ่งใช้กันมานานและยังเป็นเส้นฐานที่แข็งแรงจนถึงปัจจุบัน [27] กฎที่ใช้ตัดคำมี 2 ข้อ ข้อแรกคือตัดคำที่อยู่ในรายการคำที่ไม่ช่วยแยกจำนวน 13 คำ ซึ่งแบ่งเป็นคำไวยากรณ์ที่ปรากฏในชื่อสินค้าแทบทุกชิ้น และคำที่พบบ่อยในชื่อสินค้า จนไม่บอกความตรง เช่นคำที่หมายถึงชุด แพ็ก นิ้ว และขนาด ข้อที่สองคือตัดคำที่สั้นกว่า 3 ตัวอักษร เพราะจับคู่ตรงกันโดยบังเอิญได้ง่าย

ที่มาของกฎทั้งสองข้อคือการกำหนดด้วยมือ ไม่ได้มาจากการเรียนรู้จากข้อมูล และยังไม่ได้กวาดค่าเปรียบเทียบกับทางเลือกอื่น ซึ่งต่างจากน้ำหนักของสัญญาณ และค่าเกณฑ์คัดที่เลือกมาจากการวัด ทางเลือกที่เป็นมาตรฐานกว่าคือการถ่วงน้ำหนักคำ ตามความถี่ผกผันในคลัง ซึ่งจะทำให้ระบบหาเองได้ว่าคำใดไม่ช่วยแยกและปรับตามโดเมนได้เอง โครงงานนี้เลือกรายการตายตัวเพราะอธิบายได้ทุกคำและให้ผลเดิมทุกครั้ง ซึ่งจำเป็นกับงานที่ต้องทำซ้ำได้ แต่เป็นการแลกเปลี่ยน ไม่ใช่ทางเลือกที่ดีกว่าเสมอไป

ผลข้างเคียงที่วัดได้ของกฎตัดคำสั้น คือคำค้นที่เขียนหน่วยแยกจากตัวเลข จะถูกตัดทั้งตัวเลขและหน่วยทิ้ง ทำให้สัญญาณนี้แยกความจุที่ต่างกันไม่ได้ ดัง

ตัวอย่างในตารางที่ 17

ตารางที่ 17 ผลของกฎตัดคำสั้นต่อคำค้นที่มีตัวเลขและหน่วย

รูปแบบคำค้น		**สินค้า 2 TB**	**สินค้า 1 TB**
เขียนติดกัน	usb flash drive 2tb	1.00	**0.75**
เขียนแยกคำ	usb flash drive 2 tb	1.00	**1.00**

กล่าวคือสัญญาณนี้จับคำเงื่อนไขที่ยาวตั้งแต่ 3 ตัวอักษรขึ้นไปได้ดี เช่น คำบอกลักษณะหรือชื่อแบรนด์ แต่จับตัวเลขและหน่วยสั้นที่เขียนแยกคำไม่ได้ ซึ่งเป็นข้อจำกัดที่ยังไม่ได้แก้ในโครงงานนี้

เหตุผลเชิงทฤษฎีที่สัญญาณนี้ได้ผลคือ**การนับคำซ้อนไม่ได้มาจากเวกเตอร์** จึงผิดพลาดคนละแบบกับสัญญาณเดิมและเสริมกันได้ ซึ่งสอดคล้องกับงานที่พบว่าการผสมสัญญาณแบบจับคู่คำเข้ากับการค้นด้วยเวกเตอร์ให้ผลดีกว่าใช้อย่างใดอย่างหนึ่ง [28, 29] และสอดคล้องกับการประเมินข้ามโดเมนที่พบว่าแบบจำลองเวกเตอร์เสียเปรียบเมื่อคำค้นต้องการการจับคู่คำตรงตัว [30] ข้อจำกัดคือฝั่งไทยไม่ได้ประโยชน์จากสัญญาณนี้ เพราะนับคำซ้อนกับคำแปล ไม่ใช่คำที่ผู้ใช้พิมพ์จริง ความคลาดเคลื่อนของชั้นแปลจึงไหลลงมาทำลายสัญญาณปลายน้ำ

4.6.3 ความสามารถที่แท้จริงของการค้นซ้ำ

เมื่อตรวจสอบว่าการค้นซ้ำช่วยอย่างไร พบว่า**ไม่ใช่การแก้คำสะกดผิดอย่างที่เข้าใจตอนแรก** การทดสอบกับคำค้นที่สะกดผิดพบว่ากู้คืนได้เพียง 3 จาก 12 คำ กรณีที่สำเร็จเป็นชื่อแบรนด์ดังที่แบบจำลองรู้จักอยู่แล้ว

ความสามารถจริงของการค้นซ้ำคือ**การเปลี่ยนไปใช้คำที่คลังสินค้าใช้เรียก** ซึ่งเป็นงานทางภาษาที่แบบจำลองทำได้ดี ต่างจากการตัดสินความตรงซึ่งแบบจำลองขนาดนี้ทำไม่ได้

4.7 ผลเชิงลบที่รายงานไว้

โครงงานนี้ทดลองแนวทาง 3 อย่างที่คาดว่าจะช่วย แต่วัดแล้วไม่ได้ผล จึงรายงานไว้พร้อมหลักฐาน เนื่องจากแต่ละข้อตัดความเป็นไปได้ทางหนึ่งออกด้วยการวัด ไม่ใช่การคาดเดา

4.7.1 ให้เอเจนต์ปรับน้ำหนักของสัญญาณเอง

ทดลองให้แบบจำลองภาษาเพิ่มน้ำหนักของสัญญาณการนับคำซ้อนเมื่อเห็นว่าผลลัพธ์ยังไม่ตรง ผลคือ**การตั้งน้ำหนักเป็น 20 40 และ 100 ให้ลำดับผลลัพธ์เหมือนกันทุกประการ** ซึ่งเป็นหลักฐานโดยตรงว่าวิธีรวมอันดับที่ใช้นั้น**อิ่มตัว** เพราะใช้เฉพาะอันดับไม่ใช้ค่าดิบ นอกจากนี้ เมื่อคะแนนการนับคำซ้อนต่ำ ย่อมแปลว่าสินค้าในกองไม่มีคำที่ผู้ใช้ขอมาตั้งแต่แรก การจัดอันดับใหม่จึงสร้างสินค้าที่ไม่มีขึ้นมาไม่ได้

4.7.2 ให้เอเจนต์ระบุว่าเงื่อนไขข้อใดที่ผลลัพธ์ยังไม่ตอบ

ทดลองให้แบบจำลองภาษาอ่านคำค้นและผลลัพธ์ แล้วบอกว่าเงื่อนไขข้อใดยังไม่ถูกตอบ เพื่อนำคำนั้นไปถ่วงน้ำหนักให้หนักขึ้น ผลคือ**แย่ลง 1.1 ถึง 3.6 จุด** สาเหตุคือ

แบบจำลองทิ้งคำที่ควรเก็บ เช่น ทิ้งคำที่เป็นชื่อแบรนด์เพราะเข้าใจว่าไม่ใช่เงื่อนไข และเก็บคำที่ไม่ใช่เงื่อนไข เมื่อเทียบกันแล้วพบว่า**การหาคำที่ขาดด้วยกฎในโปรแกรมแม่นยำกว่าการให้แบบจำลองหา** โดยทำได้ถูกต้อง 73 ถึง 83 เปอร์เซ็นต์ของคำค้น

ผลข้อนี้เป็น**หลักฐานชิ้นที่สาม**ที่ชี้ไปทางเดียวกันว่าแบบจำลองขนาด 8 พันล้านพารามิเตอร์ตัดสินความตรงของสินค้าไม่ได้ ต่อจากการวัดความสอดคล้องของแบบจำลองในบทบาทผู้ตัดสินที่ได้ค่าเพียง 0.08 ถึง 0.25 และการให้แบบจำลองตรวจแก้งานตัวเองที่ล้มเหลว

4.7.3 บังคับให้ค้นซ้ำเมื่อชื่อสินค้าไม่มีคำที่ผู้ใช้ขอ

ทดลองเพิ่มกฎว่าหากชื่อสินค้าที่เลือกได้ไม่มีคำที่ผู้ใช้ขอ ให้บังคับค้นซ้ำ ผลคือกฎนี้**เป็นที่มาของการแพ้ทั้งหมด** โดยทำให้ชนะ 5 แพ้ 4 ขณะที่กฎเดิมซึ่งดูเพียงว่าได้สินค้าครบหรือไม่ ชนะ 12 แพ้ 0

สาเหตุคือคลังสินค้าใช้คำเรียกต่างจากที่ผู้ใช้ใช้ กระถางที่ปลูกกุหลาบได้ไม่จำเป็นต้องมีคำว่ากุหลาบอยู่ในชื่อสินค้า

บทเรียนที่ใช้ได้กับทั้งโครงงาน คือการนับคำซ้อน**ใช้ได้ที่ชั้นจัดอันดับ แต่ใช้ไม่ได้ที่สวิตช์เปิดการค้นซ้ำ** เพราะการจัดอันดับเป็นการเปรียบเทียบของในกองเดียวกัน ส่วนการตัดสินใจค้นซ้ำต้องใช้เกณฑ์สัมบูรณ์

4.7.4 ผลของการถอดกฎดังกล่าวออกเป็นการแลกเปลี่ยน

การถอดกฎบังคับค้นซ้ำออกไม่ได้ดีขึ้นทุกด้าน แต่เป็นการแลกเปลี่ยน จึงรายงานทั้งสองชุดดังตารางที่ 18 ไม่เลือกรายงานเฉพาะชุดที่ให้ผลดี

ตารางที่ 18 เปรียบเทียบผลก่อนและหลังถอดกฎบังคับค้นซ้ำ

รายการ	ยังเปิดกฎ	ถอดกฎออก (ที่รายงาน)
อังกฤษ	ชนะ 9 **แพ้ 3** · $p = 0.0239$	ชนะ 8 **แพ้ 0** · $p = 0.0078$
ไทย	ชนะ 8 **แพ้ 1** · $p = 0.0195$	ชนะ 5 **แพ้ 0** · $p = 0.0625$
ปฏิเสธถูก อังกฤษ · ไทย	48/60 · 49/60	**50/60 · 51/60**

ฝั่งอังกฤษดีขึ้นทุกด้าน แต่ฝั่งไทยหลุดนัยสำคัญเพราะการค้นซ้ำทำงานน้อยลงจึงชนะน้อยลงตามไปด้วย สรุปคือเป็นการแลกระหว่างการชนะหลายข้อกับการไม่แพ้เลยแม้แต่ข้อเดียว โครงงานนี้เลือกอย่างหลังเพราะระบบที่ไม่เคยแย่ลงกว่าระบบพื้นฐานมีความเสี่ยงในการนำไปใช้จริงต่ำกว่า

บทที่ 5
สรุปผลการดำเนินงาน

5.1 สรุปผลการดำเนินโครงงาน

5.1.1 ผลตามวัตถุประสงค์แต่ละข้อ

สรุปผลเทียบกับวัตถุประสงค์ที่ตั้งไว้ในบทที่ 1 แสดงดังตารางที่ 19

ตารางที่ 19 สรุปผลตามวัตถุประสงค์

ข้อ	วัตถุประสงค์	สถานะ	หลักฐาน
1	พัฒนา ระบบ แนะนำ สินค้า สอง ภาษาบนเครื่องส่วนบุคคล	บรรลุ	รันครบ 840 คำตอบ ไม่มีข้อใดทำงานผิดพลาด
2	เปรียบ เทียบ RAG กับ Agentic RAG แบบเปลี่ยนตัวแปรทีละตัว	บรรลุ	ทุก สถาปัตยกรรม ใช้ ส่วน ประกอบ ร่วม กัน ต่าง เฉพาะ ชั้น ตัดสินใจ
3	ศึกษาว่าความสามารถตัดสินใจเอง ช่วยในสถานการณ์ใด	บรรลุ	ช่วย เฉพาะ กลุ่ม ที่ คลัง ไม่มี สินค้า ตรง ไม่ช่วยเลยเมื่อคลังมีของ
4	สร้างและเผยแพร่ชุดทดสอบพร้อม เฉลย	บรรลุ	เผย แพร่ คำ ค้น 140 คำ เฉลย ความตรง 591 คู่ และเฉลยความ ซื่อตรง 402 รายการ

5.1.2 คำตอบของคำถามวิจัย

คำถามที่ 1 สถาปัตยกรรมแบบ Agentic RAG ให้ผลดีกว่าแบบ RAG มาตรฐานหรือไม่

ตอบว่า**ดีกว่าทั้งสองภาษา และไม่แพ้แม้แต่ข้อเดียว** ฝั่งอังกฤษ nDCG@3 เพิ่มจาก 0.3288 เป็น 0.3564 ดีขึ้น 8 ข้อ แย่ลง 0 ข้อ ที่ $p = 0.0078$ ฝั่งไทยเพิ่มจาก 0.3165 เป็น 0.3267 ดีขึ้น 5 ข้อ แย่ลง 0 ข้อ ที่ $p = 0.0625$ ซึ่งเป็นค่าต่ำสุดที่เป็นไปได้เมื่อมีข้อที่ต่างกัน 5 ข้อ

คำถามที่ 2 ความได้เปรียบนั้นมาจากไหน

ตอบว่า**มาจากกลุ่มที่คลังไม่มีสินค้าตรงเพียงกลุ่มเดียว** ในกลุ่มที่คลังมีสินค้าตรง ทั้งสามสถาปัตยกรรมได้คะแนนเท่ากันทุกทศนิยมในฝั่งอังกฤษ และสถิติการทำงานยืนยันว่าการค้นซ้ำไม่ทำงานเลยเมื่อคลังมีของ ข้อสรุปเชิงปฏิบัติคือ**ความเป็นเอเจนต์คุ้มค่าเมื่อคำค้นมีโอกาสหาของไม่เจอ ไม่ใช่ทุกกรณี**

คำถามที่ 3 ควรขยายขอบเขตการตัดสินใจของเอเจนต์ไปถึงการคุมการค้นซ้ำหรือไม่

ตอบว่า**ไม่คุ้ม** เพราะ A3C กับ A3 ให้ผล nDCG เท่ากันทุกทศนิยมทั้งสองภาษา แต่ A3 ใช้การเรียกแบบจำลองมากกว่าประมาณ 1.3 ครั้งต่อข้อ และใช้เวลามากกว่าประมาณ 5

วินาทีต่อข้อ คู่นี้เป็นคู่เดียวที่เปลี่ยนตัวแปรทีละตัวอย่างแท้จริง คำตอบจึงเชื่อถือได้

5.1.3 ข้อค้นพบที่สำคัญที่สุด

ข้อค้นพบที่มีผลต่อการออกแบบระบบมากที่สุด**ไม่ใช่เรื่องสถาปัตยกรรม แต่เป็นเรื่องชั้นจัดอันดับ** การตรวจสอบทุกขั้นของระบบพบว่าชั้นจัดอันดับทำสินค้าที่ดีสูญหายไป 45 ถึง 48 เปอร์เซ็นต์ ซึ่งมากกว่าทุกชั้นอื่นรวมกันประมาณ 3.5 เท่า

เมื่อเพิ่มสัญญาณการนับคำที่ซ้อนกับคำค้นเข้าไปในชั้นจัดอันดับ ได้ผลเพิ่มขึ้น 3.4 ถึง 3.5 จุดแบบตลอดสาย ซึ่ง**มากกว่าผลที่ความเป็นเอเจนต์ให้ประมาณ 2 เท่า** ข้อค้นพบนี้ชี้ว่าในระบบลักษณะนี้ การปรับปรุงส่วนประกอบพื้นฐานอาจให้ผลตอบแทนสูงกว่าการเพิ่มความซับซ้อนของสถาปัตยกรรม

5.2 ข้อจำกัดของโครงงาน

1) **ขนาดของแบบจำลองภาษา** ใช้แบบจำลองขนาด 8 พันล้านพารามิเตอร์ ซึ่งเป็นขนาดใหญ่ที่สุดที่ทำงานได้บนหน่วยความจำกราฟิก 8 กิกะไบต์ ข้อสรุปที่ว่าแบบจำลองตัดสินความตรงไม่ได้จึงผูกกับขนาดนี้ และสรุปไปถึงแบบจำลองขนาดใหญ่กว่าไม่ได้

2) **ไม่มีผู้ติดป้ายอิสระคนที่สอง** เฉลยทั้งหมดติดโดยผู้วิจัยซึ่งเป็นผู้พัฒนาระบบที่ถูกประเมินเอง จึงยังรายงานค่าความสอดคล้องระหว่างผู้ติดป้ายไม่ได้ และยืนยันไม่ได้ว่าเกณฑ์ที่ใช้ตรงกับที่ผู้อื่นจะตัดสิน

3) **ความเอนเอียงของกองที่ติดเฉลย** กองที่ติดเฉลยมาจากสินค้าที่ระบบของโครงงานนี้หยิบขึ้นมาเท่านั้น ระบบอื่นที่หยิบสินค้านอกกองจะถูกประเมินต่ำกว่าความเป็นจริง

4) **ตัวหารของ nDCG ไม่เป็นมาตรฐาน** ใช้ระบบในอุดมคติเป็นตัวหารแทนกองที่ติดเฉลย ค่าที่ได้จึงเทียบกับงานวิจัยอื่นโดยตรงไม่ได้

5) **คำค้นภาษาไทยเป็นคำแปล** ไม่ใช่คำที่ผู้ใช้ชาวไทยพิมพ์เอง ความยากจากการสะกดผิดจึงหายไปบางส่วน และในกลุ่มที่คลังไม่มีของ มีคำที่แปลจริงเพียง 15 จาก 60 คำ เพราะที่เหลือเป็นชื่อเฉพาะที่แปลไม่ได้ ทำให้กองไทยกลุ่มนี้ซ้อนทับกองอังกฤษถึง 75 เปอร์เซ็นต์ ตัวเลขฝั่งไทยในกลุ่มนี้จึงไม่ใช่การวัดภาษาไทยที่เป็นอิสระ

6) **ชุดทดสอบไม่มีสถานะกลาง** ไม่ครอบคลุมกรณีที่คลังมีสินค้าใกล้เคียงแต่ไม่ตรง ซึ่งเป็นสถานการณ์ที่การค้นซ้ำน่าจะได้เปรียบมากที่สุด การประเมินจึงอาจต่ำกว่าประโยชน์จริง

7) **กฎตัดคำของสัญญาณนับคำซ้อนกำหนดด้วยมือ** รายการคำที่ไม่ช่วยแยก 13 คำ และเกณฑ์ตัดคำที่สั้นกว่า 3 ตัวอักษร เขียนขึ้นเองโดยไม่ได้เรียนรู้จากข้อมูลและไม่ได้กวาดค่าเปรียบเทียบกับทางเลือกอื่น จึงยืนยันไม่ได้ว่าเป็นค่าที่ดีที่สุด และผูกกับ

โดเมนสินค้ากับภาษาอังกฤษ ผลข้างเคียงที่วัดได้คือคำค้นที่เขียนตัวเลขแยกจากหน่วยจะถูกตัดทิ้งทั้งคู่ ทำให้สัญญาณแยกความจุที่ต่างกันไม่ได้

8) **ปรับค่าน้ำหนักบนชุดเดียวกับที่รายงานผล** น้ำหนักของสัญญาณการนับคำซ้อนเลือกจากการกวาดค่าบนเฉลยชุดเดียวกับที่ใช้รายงาน ไม่ได้แบ่งกองพัฒนาออกจากกองทดสอบในขั้นนี้

9) **เฉลยความซื่อตรงเป็นของรุ่นก่อน** เฉลยความซื่อตรงของคำตอบวัดบนคำตอบที่ได้ก่อนเปลี่ยนชั้นจัดอันดับ เมื่อสินค้าที่หยิบเปลี่ยน คำตอบย่อมเปลี่ยนตาม ค่าที่รายงานจึงใช้กับระบบรุ่นปัจจุบันโดยตรงไม่ได้

5.3 ปัญหา อุปสรรค และแนวทางแก้ไข

5.3.1 การเปรียบเทียบที่เปลี่ยนหลายตัวแปรพร้อมกัน

ปัญหา รุ่นแรกของการทดลองเปรียบเทียบ RAG กับ Agentic RAG โดยที่สองสถาปัตยกรรมต่างกันทั้งชั้นวางแผนและชั้นค้นซ้ำพร้อมกัน จึงสรุปไม่ได้ว่าผลมาจากส่วนใด

แนวทางแก้ไข เพิ่มสถาปัตยกรรมที่สามที่ต่างจากแบบเต็มเพียงตัวแปรเดียว ทำให้ได้คู่เปรียบเทียบที่เปลี่ยนตัวแปรทีละตัวอย่างแท้จริง

5.3.2 กองที่ติดเฉลยใช้วัดระบบที่เปลี่ยนไปแล้วไม่ได้

ปัญหา หลังเปลี่ยนชั้นจัดอันดับ สินค้าที่ระบบหยิบขึ้นมาเปลี่ยนไปถึง 51 จาก 80 คำค้น สินค้าใหม่ไม่มีเฉลย และวิธีคิดตัวชี้วัดตัดคำค้นที่เฉลยไม่ครบทิ้งทั้งข้อ เหลือคำค้นที่เทียบได้เพียง 21 จาก 50 คำ และเกือบทั้งหมดเป็นคำที่ไม่มีอะไรเปลี่ยน จึงวัดอะไรไม่ได้

แนวทางแก้ไข ติดเฉลยเพิ่มสำหรับสินค้าที่โผล่ขึ้นมาใหม่ จนชุดคำค้นที่เทียบได้ครบกลับมาเป็น 140 จาก 140 คำ และบันทึกข้อจำกัดนี้ไว้ในรายงาน

5.3.3 การทดสอบที่ผ่านแต่ไม่ครอบคลุมเส้นทางจริง

ปัญหา การเพิ่มสัญญาณใหม่เข้าไปในชั้นจัดอันดับทำให้การเรียกใช้งานบางเส้นทางขาดพารามิเตอร์ แต่การทดสอบเบื้องต้นผ่านเพราะกรณีทดสอบที่ใช้ไม่ได้วิ่งผ่านเส้นทางนั้น ปัญหาจึงไปปรากฏตอนรันจริงและทำให้การรันล้มเหลวจำนวนมาก

แนวทางแก้ไข กำหนดเป็นแนวปฏิบัติว่าการทดสอบต้องใช้กรณีที่**ทำให้เส้นทางใหม่ทำงานจริง** ไม่ใช่เพียงกรณีที่ไม่ทำให้โปรแกรมหยุด

5.3.4 ความเข้าใจผิดเกี่ยวกับความสามารถของการค้นซ้ำ

ปัญหา ตอนแรกเข้าใจว่าการค้นซ้ำช่วยเพราะแก้คำสะกดผิดได้ การทดสอบกับคำที่สะกดผิดพบว่ากู้คืนได้เพียง 3 จาก 12 คำ และกรณีที่สำเร็จเป็นชื่อแบรนด์ดังที่แบบจำลองรู้จักอยู่แล้ว

แนวทางแก้ไข ตรวจสอบสมมติฐานด้วยการวัดก่อนนำไปเขียนเป็นข้อสรุป และแก้คำอธิบายให้ตรงกับหลักฐาน คือการค้นซ้ำช่วยด้วยการเปลี่ยนไปใช้คำที่คลังสินค้าใช้เรียก

5.4 ข้อเสนอแนะในการพัฒนาต่อไป

1) **หาผู้ติดป้ายอิสระคนที่สอง** มาติดเฉลยซ้ำบนชุดตรวจ 48 คู่ที่เตรียมไว้แล้ว เพื่อยืนยันว่าเกณฑ์ที่ใช้ตรงกับที่ผู้อื่นจะตัดสิน ซึ่งจะทำให้รายงานค่าความสอดคล้องระหว่างผู้ติดป้ายได้

2) **เพิ่มกลุ่มคำค้นที่คลังมีสินค้าใกล้เคียงแต่ไม่ตรง** เพื่อวัดประโยชน์ของการค้นซ้ำในสถานการณ์ที่ควรได้เปรียบที่สุด ซึ่งชุดทดสอบปัจจุบันยังไม่ครอบคลุม

3) **ติดเฉลยความซื่อตรงของคำตอบใหม่** บนคำตอบที่ได้จากระบบรุ่นปัจจุบัน เพื่อให้ตัวชี้วัดด้านนี้ตรงกับระบบที่รายงาน

4) **ถ่วงน้ำหนักคำตามความถี่ผกผันในคลัง** แทนการใช้รายการคำที่ไม่ช่วยแยกแบบเขียนเอง เพื่อให้ระบบหาได้เองว่าคำใดไม่ช่วยแยกความตรง ซึ่งจะปรับตามโดเมนได้โดยอัตโนมัติ และแก้ปัญหาที่ตัวเลขกับหน่วยสั้นถูกตัดทิ้ง

5) **ใช้คำค้นภาษาไทยที่ผู้ใช้ไทยพิมพ์เอง** แทนคำแปล เพื่อให้ความยากที่เกิดจากการสะกดและการเลือกคำสะท้อนการใช้งานจริง

6) **ทดสอบกับแบบจำลองภาษาขนาดใหญ่กว่า** เพื่อตรวจว่าข้อสรุปที่ว่าแบบจำลองตัดสินความตรงไม่ได้นั้นเป็นข้อจำกัดของขนาด หรือเป็นข้อจำกัดของแนวทาง

7) **ปรับปรุงชั้นแปลภาษา** เนื่องจากความคลาดเคลื่อนของชั้นนี้ไหลลงไปทำลายสัญญาณปลายน้ำ โดยเฉพาะสัญญาณการนับคำซ้อนซึ่งฝั่งไทยไม่ได้ประโยชน์เลย

8) **พัฒนาส่วนติดต่อผู้ใช้** เพื่อให้ทดสอบกับผู้ใช้จริงได้ ซึ่งจะเปิดทางไปสู่การวัดความพึงพอใจและความมีประโยชน์ที่ตัวชี้วัดปัจจุบันยังวัดไม่ได้

เอกสารอ้างอิง

[1] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, "Retrieval-augmented generation for knowledge-intensive NLP tasks," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

[2] S. Jeong, J. Baek, S. Cho, S. J. Hwang, and J. C. Park, "Adaptive-RAG: Learning to adapt retrieval-augmented large language models through question complexity," *arXiv preprint arXiv:2403.14403*, 2024.

[3] S.-Q. Yan, J.-C. Gu, Y. Zhu, and Z.-H. Ling, "Corrective retrieval augmented generation," *arXiv preprint arXiv:2401.15884*, 2024.

[4] A. Singh, A. Ehtesham, S. Kumar, and T. T. Khoei, "Agentic retrieval-augmented generation: A survey on agentic RAG," *arXiv preprint arXiv:2501.09136*, 2025.

[5] Y. Hou, J. Li, Z. He, A. Yan, X. Chen, and J. McAuley, "Bridging language and items for retrieval and recommendation," *arXiv preprint arXiv:2403.03952*, 2024.

[6] C. K. Reddy, L. Màrquez, F. Valero, N. Rao, H. Zaragoza, S. Bandyopadhyay, A. Biswas, A. Xing, and K. Subbian, "Shopping queries dataset: A large-scale ESCI benchmark for improving product search," *arXiv preprint arXiv:2206.06588*, 2022.

[7] Y. Chen, S. Liu, Z. Liu, W. Sun, L. Baltrunas, and B. Schroeder, "WANDS: Dataset for product search relevance assessment," in *Advances in Information Retrieval (ECIR)*, pp. 128–141, 2022.

[8] K. Järvelin and J. Kekäläinen, "Cumulated gain-based evaluation of IR techniques," *ACM Transactions on Information Systems*, vol. 20, no. 4, pp. 422–446, 2002.

[9] M. D. Smucker, J. Allan, and B. Carterette, "A comparison of statistical significance tests for information retrieval evaluation," *Proceedings of the 16th ACM Conference on Information and Knowledge Management (CIKM)*, pp. 623–632, 2007.

[10] J. Zobel, "How reliable are the results of large-scale information retrieval experiments?," in *Proceedings of the 21st International ACM SIGIR Conference*, pp. 307–314, 1998.

[11] Y. Gao, Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun, M. Wang, and H. Wang, "Retrieval-augmented generation for large language models: A survey," *arXiv preprint arXiv:2312.10997*, 2023.

[12] Y. Gao, Y. Xiong, M. Wang, and H. Wang, "Modular RAG: Transforming RAG systems into LEGO-like reconfigurable frameworks," *arXiv preprint arXiv:2407.21059*, 2024.

[13] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, "BGE M3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation," *arXiv preprint arXiv:2402.03216*, 2024.

[14] Y. A. Malkov and D. A. Yashunin, "Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 42, no. 4, pp. 824–836, 2020.

[15] G. V. Cormack, C. L. A. Clarke, and S. Buettcher, "Reciprocal rank fusion outperforms condorcet and individual rank learning methods," in *Proceedings of the 32nd International ACM SIGIR Conference*, pp. 758–759, 2009.

[16] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su, Y. Xu, E. Ishii, Y. Bang, A. Madotto, and P. Fung, "Survey of hallucination in natural language generation," *ACM Computing Surveys*, vol. 55, no. 12, pp. 1–38, 2023.

[17] J. Maynez, S. Narayan, B. Bohnet, and R. McDonald, "On faithfulness and factuality in abstractive summarization," in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, pp. 1906–1919, 2020.

[18] H. Rashkin, V. Nikolaev, M. Lamm, L. Aroyo, M. Collins, D. Das, S. Petrov, G. S. Tomar, I. Turc, and D. Reitter, "Measuring attribution in natural language generation models," *Computational Linguistics*, vol. 49, no. 4, pp. 777–840, 2023.

[19] E. M. Voorhees and D. K. Harman, *TREC: Experiment and Evaluation in Information Retrieval*. MIT Press, 2005.

[20] J. Cohen, "Weighted kappa: Nominal scale agreement with provision for scaled disagreement or partial credit," *Psychological Bulletin*, vol. 70, no. 4, pp. 213–220, 1968.

[21] J. R. Landis and G. G. Koch, "The measurement of observer agreement for categorical data," *Biometrics*, vol. 33, no. 1, pp. 159–174, 1977.

[22] R. Artstein and M. Poesio, "Inter-coder agreement for computational linguistics," *Computational Linguistics*, vol. 34, no. 4, pp. 555–596, 2008.

[23] J. Pustejovsky and A. Stubbs, *Natural Language Annotation for Machine Learning*. O'Reilly Media, 2012.

[24] C. Buckley and E. M. Voorhees, "Evaluating evaluation measure stability," in *Proceedings of the 23rd International ACM SIGIR Conference*, pp. 33–40, 2000.

[25] E. M. Voorhees, "Variations in relevance judgments and the measurement of retrieval effectiveness," *Information Processing and Management*, vol. 36, no. 5, pp. 697–716, 2000.

[26] K. Ethayarajh, "How contextual are contextualized word representations? comparing the geometry of BERT, ELMo, and GPT-2 embeddings," in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2019.

[27] S. Robertson and H. Zaragoza, "The probabilistic relevance framework: BM25 and beyond," *Foundations and Trends in Information Retrieval*, vol. 4, no. 1–2, pp. 1–174, 2009.

[28] V. Karpukhin, B. Oğuz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W.-t. Yih, "Dense passage retrieval for open-domain question answering," in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2020.

[29] Y. Luan, J. Eisenstein, K. Toutanova, and M. Collins, "Sparse, dense, and attentional representations for text retrieval," *Transactions of the Association for Computational Linguistics*, vol. 9, pp. 329–345, 2021.

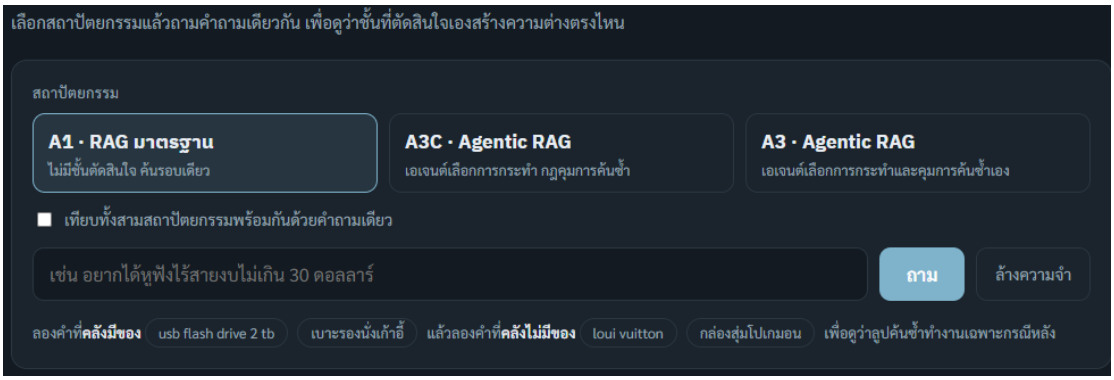
[30] N. Thakur, N. Reimers, A. Rücklé, A. Srivastava, and I. Gurevych, "BEIR: A heterogenous benchmark for zero-shot evaluation of information retrieval models," *arXiv preprint arXiv:2104.08663*, 2021.

ภาคผนวก ก
หน้าจอสาธิตระบบ

ภาพรวมของหน้าจอสาธิต

โครงงานนี้พัฒนาหน้าจอสาธิตขึ้นเพื่อให้ทดลองใช้ระบบได้จริง และเพื่อให้เห็นความต่างระหว่างสถาปัตยกรรมทั้งสามแบบขณะทำงาน หน้าจอนี้ทำงานบนเครื่องส่วนบุคคลเช่นเดียวกับตัวระบบ และเรียกใช้สถาปัตยกรรมตัวจริงชุดเดียวกับที่ใช้วัดผลในบทที่ 4 ไม่ได้แสดงผลลัพธ์ที่เตรียมไว้ล่วงหน้า

หน้าจอหลักก่อนเริ่มถามคำถามแสดงดังภาพที่ 4



ภาพที่ 4 หน้าจอหลักของระบบสาธิต ส่วนเลือกสถาปัตยกรรมและช่องพิมพ์คำถาม

ส่วนประกอบของหน้าจอแบ่งเป็น 4 ส่วน ดังนี้

1) **ส่วนเลือกสถาปัตยกรรม** ผู้ใช้เลือกได้ว่าจะให้คำถามนี้ทำงานด้วย A1 ซึ่งเป็น RAG มาตรฐาน A3C ซึ่งเป็น Agentic RAG ที่เอเจนต์เลือกการกระทำ หรือ A3 ซึ่งเอเจนต์คุมการค้นซ้ำเองด้วย ใต้ชื่อแต่ละแบบมีคำอธิบายสั้นกำกับว่าต่างกันอย่างไร

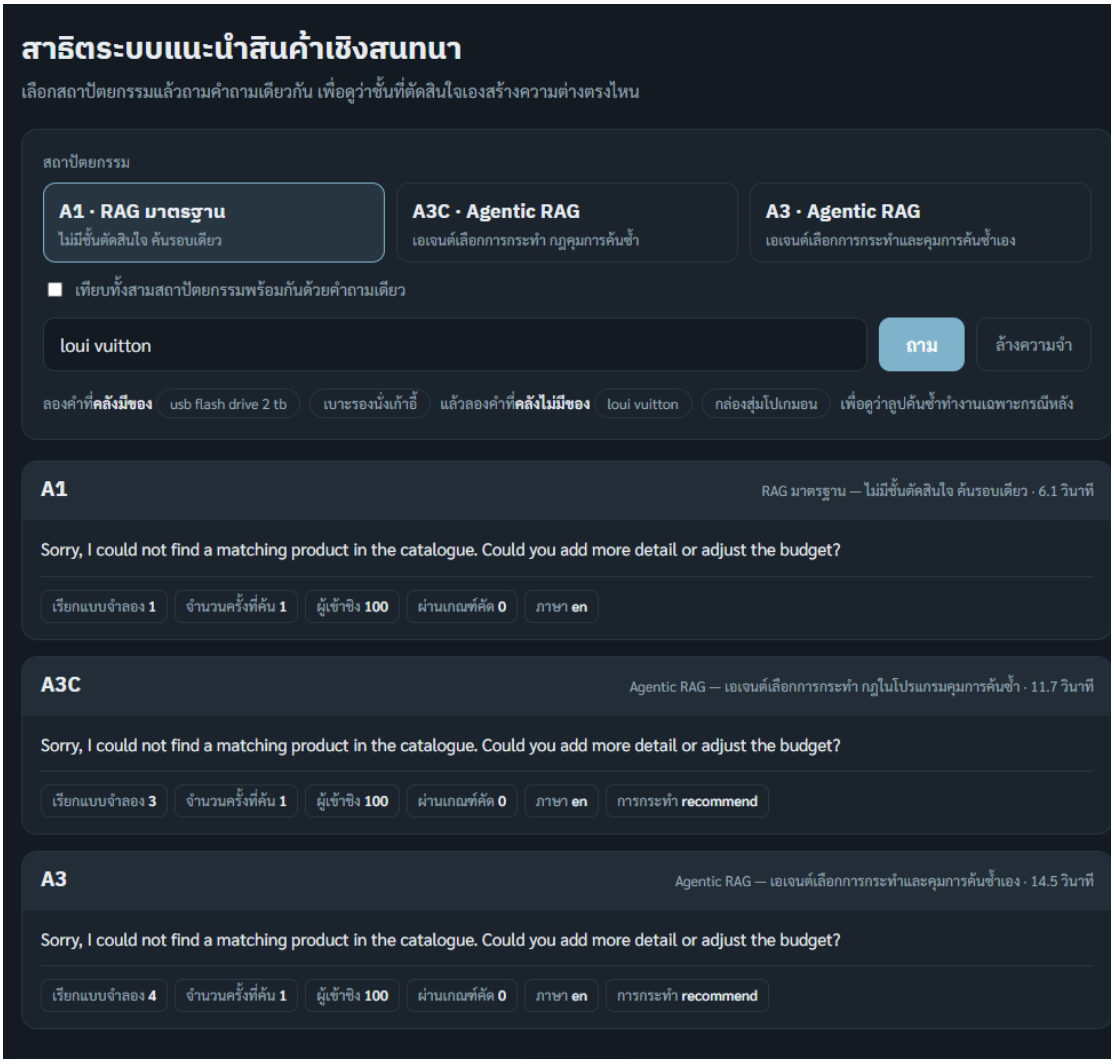
2) **ตัวเลือกเทียบทั้งสามแบบพร้อมกัน** เมื่อเปิดใช้ ระบบจะส่งคำถามเดียวกัน ไปยังทั้งสามสถาปัตยกรรมแล้วแสดงผลเรียงลงมา ทำให้เปรียบเทียบได้ในคราวเดียว

3) **ช่องพิมพ์คำถาม** รับได้ทั้งภาษาไทยและภาษาอังกฤษ ระบบตรวจภาษาเองแล้วตอบ เป็นภาษาเดียวกับที่ถาม ข้างล่างมีคำค้นตัวอย่างที่กดใช้ได้ทันที แบ่งเป็นกลุ่มที่คลังมีสินค้าและกลุ่มที่คลังไม่มีสินค้า

4) **ปุ่มล้างความจำ** เนื่องจากแต่ละสถาปัตยกรรมจดจำบทสนทนาข้ามรอบ การเริ่มคำถามใหม่ที่ไม่เกี่ยวกับคำถามก่อนจึงต้องล้างความจำก่อน

ผลการเปรียบเทียบสามสถาปัตยกรรมด้วยคำถามเดียวกัน

ภาพที่ 5 แสดงผลเมื่อเปิดโหมดเทียบทั้งสามแบบ แล้วถามด้วยคำค้น `loui vuitton` ซึ่งเป็นคำค้นจริงจากชุดทดสอบในกลุ่มที่คลังไม่มีสินค้าตรง และเป็นคำที่ผู้ใช้สะกดผิดจากคำว่า louis vuitton



ภาพที่ 5 ผลการเปรียบเทียบทั้งสามสถาปัตยกรรมด้วยคำถามเดียวกัน

การอ่านผลในภาพ

ใต้คำตอบของแต่ละสถาปัตยกรรมมีแถบตัวเลขที่ดึงมาจากการทำงานจริงของรอบนั้น ได้แก่ จำนวนครั้งที่เรียกแบบจำลองภาษา จำนวนครั้งที่ค้น จำนวนผู้เข้าชิงที่ดึงมาจากคลัง จำนวนที่ผ่านเกณฑ์คัด ภาษาที่ตรวจได้ และการกระทำที่ชั้นวางแผนเลือก สรุปค่าที่ปรากฏในภาพได้ดังตารางที่ 20

ตารางที่ 20 ค่าที่วัดได้จากหน้าจอสาธิตในภาพที่ 5

รายการ	**A1**	**A3C**	**A3**
เรียกแบบจำลองภาษา (ครั้ง)	**1**	3	4
จำนวนครั้งที่ค้น	1	1	1
ผู้เข้าชิงที่ดึงจากคลัง	100	100	100
ผ่านเกณฑ์คัด	0	0	0
เวลาที่ใช้ (วินาที)	**6.1**	11.7	14.5
คำตอบ	ไม่พบ	ไม่พบ	ไม่พบ

สิ่งที่ภาพนี้แสดงมี 3 ประการ

1) **ทั้งสามสถาปัตยกรรมปฏิเสธถูกต้องตรงกัน** เนื่องจากไม่มีสินค้าใดผ่านเกณฑ์คัดเลยแม้แต่ชิ้นเดียว ระบบจึงตอบว่าไม่พบแทนที่จะเสนอสินค้าที่ไม่ตรง ซึ่งเป็นพฤติกรรมที่ถูกต้องสำหรับคำค้นกลุ่มนี้

2) **ต้นทุนเพิ่มขึ้นตามความเป็นเอเจนต์ แต่ผลลัพธ์เท่ากัน** A1 เรียกแบบจำลอง เพียงครั้งเดียวและใช้เวลา 6.1 วินาที ขณะที่ A3 เรียก 4 ครั้ง และใช้เวลา 14.5 วินาที หรือราว 2.4 เท่า ทั้งที่ได้คำตอบเหมือนกันทุกประการ ข้อสังเกตนี้สอดคล้องกับข้อสรุปในบทที่ 5 ที่ว่าการขยายขอบเขตการตัดสินใจของ เอเจนต์ไปถึงการคุมการค้นซ้ำนั้นไม่คุ้มกับต้นทุนที่เพิ่มขึ้น

3) **ชั้นวางแผนทำงานจริง** A3C และ A3 แสดงการกระทำที่เลือกไว้ว่า recommend ขณะที่ A1 ไม่มีช่องนี้เพราะไม่มีชั้นวางแผน จึงค้นทันทีทุกครั้ง

ข้อสังเกตเรื่องความจำกับการสาธิต

ในภาพที่ 5 จำนวนครั้งที่ค้นของทั้งสามสถาปัตยกรรมเท่ากับ 1 กล่าวคือ**การค้นซ้ำไม่ได้ทำงาน** ทั้งที่คำค้นนี้อยู่ในกลุ่มที่คลังไม่มีสินค้า สาเหตุคือรอบนั้นได้ถามคำถามเดียวกันไปก่อนหน้าแล้ว ระบบจึงจดจำไว้ว่าเคยพยายามค้นด้วย คำนี้แล้วไม่พบ และไม่พยายามซ้ำอีก

เมื่อล้างความจำแล้วถามใหม่ด้วยคำเดียวกัน การค้นซ้ำทำงานตามที่ออกแบบไว้ คือค้น 2 รอบ และเรียกแบบจำลองภาษา 4 ครั้งสำหรับ A3C โดยคำค้นที่ระบบเขียนขึ้นใหม่ในรอบที่สองคือ louis vuitton ซึ่งเป็นการแก้คำสะกดจาก loui vuitton ได้ถูกต้อง กรณีนี้สำเร็จเพราะเป็นชื่อแบรนด์ที่แบบจำลองรู้จัก ไม่ใช่ความสามารถแก้คำสะกดทั่วไป ตามที่อธิบายไว้ในบทที่ 4

ข้อสังเกตนี้มีผลเชิงปฏิบัติคือ **การสาธิตควรล้างความจำก่อนเริ่มคำถามใหม่ทุกครั้ง** มิฉะนั้นพฤติกรรมการค้นซ้ำจะไม่ปรากฏให้เห็น

วิธีเรียกใช้งาน

ระบบสาธิตต้องเปิดบริการแบบจำลองภาษาในเครื่องก่อน แล้วจึงเปิดเซิร์ฟเวอร์ของหน้าจอสาธิต จากนั้นเข้าใช้งานผ่านเว็บเบราว์เซอร์ที่ที่อยู่ภายในเครื่อง เซิร์ฟเวอร์เขียนด้วยไลบรารีมาตรฐานของภาษาไพทอนทั้งหมด จึงไม่ต้องติดตั้งเว็บเฟรมเวิร์กเพิ่ม

ประวัติผู้เขียน

นักศึกษาคนที่ 1

นายศจิษฐา ศีลธรรมดี เกิดเมื่อวันที่ 3 กันยายน พ.ศ. 2547 สำเร็จการศึกษาระดับมัธยมศึกษาตอนปลาย จากโรงเรียนราชสีมาวิทยาลัย เมื่อปีการศึกษา 2565 ปัจจุบันกำลังศึกษาระดับปริญญาตรี หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

นักศึกษาคนที่ 2

นายนิติธร คชรัตน์ เกิดเมื่อวันที่ 22 มิถุนายน พ.ศ. 2547 สำเร็จการศึกษาระดับมัธยมศึกษาตอนปลาย จากโรงเรียนแก่นนครวิทยาลัย เมื่อปีการศึกษา 2565 ปัจจุบันกำลังศึกษาระดับปริญญาตรี หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น